域内重测

实验编号： EXP-20261005-COWCV-ID-RETEST
实验主题： 统一协议下的 YOLO11m 域内监督参照重建、可复现性审计与 LODO 保持率分析
历史执行时段： 2026-10-05—2026-10-08（主实验与 stock 运行重复）；2026-10-09—2026-10-12（effective-seed 扩展与汇总）
整理与方法核查日期： 2026-10-14，北京时间
记录性质： 既有实验的追溯整理、脚本核查与表格复算；本次未重新训练或远程推理
记录人： 待填写　　**审核人：** 待填写
格式依据： 实验记录格式参考的七项结构；将“试剂与耗材”调整为“数据、软件与计算资源”。



图 1　训练负责参数学习，验证负责权重选择，测试负责预定权重的最终评估；保持率分析使用与 LODO 相同的目标 test 视图。场景及流程为 Study Image 方法示意，不是数据集实拍或模型预测结果。

本阶段完成了 **YOLO11m×14 域**的监督参照重建。主方案的 test mAP@0.5:0.95 等权宏平均为 **0.7214**；有效种子扩展的三种子宏平均为 **0.72049±0.00159**（样本 SD，n=3）。同视图 LODO 相对域内监督参照的逐域保持率宏平均约为 **0.7328**。这三组数分别回答“单域监督能达到什么水平”“跨有效种子会怎样波动”“多源零样本保留了多少目标域监督表现”，不能混成一个统计量。（L2 §§4、6、11；本次表格复算）

本记录的研究重点包括：修正旧验证口径的证据链、冻结可追溯协议、处理误覆盖事件、查明名义 seed 与实际随机流的差异，以及建立监督参照与多源泛化的同视图比较。

目　录

1. 实验目的（Objective） 4
1.1 重测所针对的具体问题 4
1.2 研究问题与完成判据 4
1.3 范围与研究边界 4
2. 实验原理与参考依据（Principle & References） 5
2.1 域内监督参照与同视图比较 5
2.2 指标与工作点：AP、NMS 和 P/R 分别说明 5
2.3 等权宏平均、保持率与不确定性 6
2.4 固定 seed 的声明需要机制证据 7
3. 数据、软件与计算资源（Materials & Environment） 7
3.1 数据版本、目标域与实际测试规模 7
3.2 历史运行环境与初始化身份 7
3.3 冻结配置与预算差异 8
3.4 资产组织与本次访问边界 8
4. 实验步骤与过程记录（Procedures） 9
4.1 准备、冻结与冒烟 9
4.2 串行执行与实际时间线 9
4.3 保存权重并按 val 选择 10
4.4 预定 test 评测与字段修正 10
4.5 排障：误覆盖、隔离、恢复与加固 11
4.6 源码审计与 effective-seed 扩展 12
4.7 可复现操作入口 13
5. 原始记录摘录与过程现象（Raw Data & Observations） 14
5.1 主方案逐域读数与选模轮次 14
5.2 stock 重复：完全一致域与噪声域 14
5.3 es 生效的直接现象与结果 15
5.4 第 100 轮敏感性对照 16
6. 结果与数据分析（Results & Analysis） 17
6.1 同协议域内参照的总体水平 17
6.2 跨有效种子的总体稳健性 17
6.3 与 LODO 的同目标配对及保持率 19
6.4 与旧记录的描述性对照 21
7. 讨论、后续计划与阶段结论（Discussion & Next Steps） 21
7.1 本阶段的研究价值 21
7.2 来源冲突与采用口径 22
7.3 后续执行与验收 22
7.4 可采用的阶段结论 23
附录 A. 来源、文献与定位 23
A.1 本地直接阅读来源 23
A.2 本次自行核查的操作指南与原始研究 24

附录 B. 图表、复算与审核说明 **25**
B.1 可编辑与机器可读材料 25
B.2 舍入、图像来源与诚实呈现 25

1. 实验目的（Objective）

1.1 重测所针对的具体问题

2026 年 7 月的域内模型比较可用于阶段观察，但不宜直接作为本轮正式 test 参照。重测计划列出了三项需要修正的问题。（L1 §1）

1. **训练设置不统一。** 历史 YOLO11m 部分数据集使用 batch=16，其余使用 batch=32；跨模型还存在 AMP、自动优化器、有效 batch 和环境变更等差异。
2. **选模与报告集合未充分分离。** 历史主表以 val 报告，diarycow 的一个名义 test 别名也实际指向 val。以同一集合选出峰值并报告，不能替代独立冻结 test。
3. **数据版本与新泛化实验不一致。** 旧阶段划分为 23,851/4,971/2,551；新 `data/` 经 SHA-256 同图同标去重及重切，划分为 25,079/3,142/3,124。两套数据规模与划分均发生变化。

因此，本轮重测在新的 `data/` 上重新训练，而非只对旧权重换一个评测路径。所有目标域使用同一检测器、初始化、输入尺度与明确优化协议，构建与 LODO 目标 test 对齐的域内监督参照。（L1 §§1–3；L2 §§1–2）

1.2 研究问题与完成判据

本阶段围绕四个问题组织证据：

- **参照重建：** 本域 train 学习、本域 val 选模、冻结 test 报告后，各域的 $M_{t \to t}$ 是多少？
- **选择敏感性：** 按 val 最优轮选择，与预定第 100 轮权重相比，test 结果改变多少？
- **复现机制：** 运行名中的 seed=42/43/44 是否真正改变洗牌与增强随机流？重复执行的差异如何报告？
- **泛化保持：** 在同一目标 test 上，13 源 LODO 的 $M_{-t \to t}$ 相对本域监督参照保留多少表现？

验收材料包括 14 域完整训练记录、预选权重及选择依据、每轮 28 条 selected/epoch100 评测结果、test 数量核验、分协议重复结果，以及可定位的事故与恢复记录。这些材料的历史完成状态依据 L2；本次已独立检查本地文档、镜像脚本及汇总算术，未重开服务器原始产物。

1.3 范围与研究边界

本轮对象固定为 **YOLO11m**。RT-DETR-L、Faster R-CNN、RetinaNet 及 YOLO11s/l 的统一复核另行排期；当前结果不形成四架构的新 test 排名。旧 14×14 单源迁移矩阵的数据与视图也未同步更新，因此本轮不能据此计算同视图 Δ_{multi}。（L1 §§1、7；L2 §10）

表 1　域内参照的证据链

每一阶段有独立职责，test 不参与选模

阶段	输入	操作与产物	证据约束
数据冻结	data/ 与 splits/	去重、划分；固定 14 个目标 test 视图	按文件与清单核对；来源簇独立性另审计
域内训练	本域 train	YOLO11m；100 epochs；逐轮保存	训练池为本域全量；末批保留
验证选模	本域 val	AP50–95 最大；并列较早；selected.pt	只读取 val；第 100 轮为预定对照
最终评测	冻结 test	每个预选 checkpoint 输出独立结果	selected 与 epoch100 分别评测
保持率分析	同视图 LODO 三轮	R_target = LODO 均值 / 域内主方案	逐域比值后等权平均；保留 R > 1
重复审计	stock 与 es 两套运行	分别刻画运行重复与跨 seed 离散度	协议分开；SD 与极差分开

依据：重测计划 §§2–7、执行记录 §§2、5、6、11；操作状态为本地历史记录转述。

表 1　各阶段的输入、产物与证据约束。可编辑数据见表格底稿。

2. 实验原理与参考依据（Principle & References）

2.1 域内监督参照与同视图比较

设目标域 t 的 train、val、test 分别为 D_t^{train}、D_t^{val}、D_t^{test}。对 100 轮训练中的候选权重 $W_{t,e}$，冻结选模规则：

$$e_t^* = \min \ \ arg\,max_{1 \le e \le 100} \mathrm{AP}_{50:95}^{val}(W_{t,e}).$$

$$M_{t \to t} = \mathrm{AP}_{50:95}^{test}(W_{t,e_t^*}; D_t^{test}).$$

“min”表达并列选较早 epoch。训练、选择和报告依次使用不同数据职责，test 不反馈到权重选择。L1 §4 与本地 `indomain_select_checkpoint.py` 都以 val AP50–95 为依据；镜像脚本采用严格 `>` 顺序扫描，并把选择写入 `selection.json`。

LODO 的 $M_{-t \to t}$ 来自排除目标域后的 13 源训练；其选模依据为源域 val 的等权宏平均。两类模型在同一目标 test 上评估，构成协议明确的配对比较。训练池、洗牌实现和验证构成仍有声明差异，因此“同视图可比”不等于“训练样本量及优化步数相同”。（L1 §§2–3；L3 §§2、4）

Gulrajani 与 Lopez-Paz 的 *In Search of Lost Domain Generalization* 将模型选择列为域泛化评估的重要组成部分。本项目据此将“按什么集合、什么指标选模”与最终分数一起记录；该论文的方法论不直接证明本项目的结果。（R9，摘要）

2.2 指标与工作点：AP、NMS 和 P/R 分别说明

单类别 `cow` 下，本文沿用源记录的 mAP 名称；AP50–95 表示 0.50、0.55、…、0.95 共 10 个匹配 IoU 阈值的 AP 均值：

$$\mathrm{AP}_{50:95} = \frac{1}{10}\sum_{k=0}^{9} \mathrm{AP}_{0.50+0.05k}\,.$$

COCO API 的评估参数明确区分匹配 IoU、召回采样点和每图最大检测数；Ultralytics v8.4.92 检测 validator 也设置了该 10 阈值向量。本轮使用 Ultralytics 默认 evaluator，不能因此声称输出与所有 `pycocotools` 细节完全等价。（R8、R15）

三个容易混淆的量需要分别登记：

- **置信度预筛选：** v8.4.92 默认配置注释中，val 的默认 `conf` 为 0.001；这是保留候选预测的门槛。
- **NMS IoU：** 版本配置默认 `iou=0.7`，用于去除重复预测。
- **AP 匹配 IoU：** 采用 0.50–0.95 扫描，判断预测框与真值框的匹配质量。

这些是版本源码的默认设置核查，不代替历史评测的完整生效参数快照；是否有安装补丁或继承参数仍应回到当时源码及运行材料核实。（R13、R15；L2 §2.3）

本地评测镜像直接读取 `m.results_dict` 中的 P/R，没有执行另一个固定 conf=0.25 的严格计数函数。v8.4.92 `ap_per_class` 在平滑 F1 曲线上取峰值索引，再返回 P/R。因此表 4 的 P/R 为**默认汇总工作点指标**，不是统一冻结置信阈值下的 TP/FP/FN；在 test 上从曲线取得峰值也不等于在 val 上冻结阈值后测试部署工作点。AP 为本记录的主分析指标。（L5；R4）

2.3 等权宏平均、保持率与不确定性

为防止 Cows2021 的 1,040 张 test 图在汇总中主导其他域，主汇总对 14 个数据集等权：

$$\bar{M}_{\mathrm{ID}} = \frac{1}{14}\sum_{t} M_{t\to t}\,.$$

保持率采用主方案 stock 分母与 LODO 三种子平均分子：

$$R^{\mathrm{LODO}}_{\mathrm{target}}(t) = \frac{\bar{M}^{\mathrm{LODO}}_{-t\to t}}{M^{\mathrm{stock}}_{t\to t}}, \qquad \bar{R} = \frac{1}{14}\sum_{t} R^{\mathrm{LODO}}_{\mathrm{target}}(t)\,.$$

$$\bar{R} \neq \frac{\bar{M}_{\mathrm{LODO}}}{\bar{M}_{\mathrm{ID}}} \quad \text{（一般情况下）}\,.$$

$M_{t\to t}$ 是此训练预算下的经验监督参照，不是理论上限。因此 $R > 1$ 有明确含义，应保留原值。比值也受分母波动影响，尤其是小样本域和运行噪声域。（L1 §10；L2 §§5–6）

本记录分别使用：stock 重复的**实际范围与极差**，es 三种子的**样本标准差**。对有效种子 s，先算 14 域宏平均 $\bar{M}_s$，再计算：

$$\mu = \frac{1}{3}\sum_{s} \bar{M}_s, \qquad \mathrm{SD}_{seed} = \sqrt{\frac{\sum_s (\bar{M}_s - \mu)^2}{3-1}}\,.$$

不能把 14 个域的分数标准差称为“种子 SD”，也不能把三轮极差写成“±SD”。当前 SD 表示少量重复下的描述性离散度；test 抽样误差、来源簇相关性和置信区间尚未独立量化。（L2 §§5、11；L5 聚合脚本）

2.4 固定 seed 的声明需要机制证据

PyTorch v2.5.1 可复现性文档说明，固定种子并不保证跨版本、平台或 CPU/GPU 完全复现；数据加载器的 `generator` 与 `worker_init_fn` 也参与随机流控制。其 DataLoader 实现将 generator 传给 RandomSampler，并从同一 generator 抽取 worker base seed。（R6、R7）

因此，本阶段把可复现性拆成“参数写了什么”“随机流实际由什么驱动”“观察到了什么差异”三个层次。seed 空操作及 es 激活机制的具体证据见 §4.6、§5.3，适用范围限定为本地记录所述的 8.4.92、单卡、单类初始化与数据加载配置。

3. 数据、软件与计算资源（Materials & Environment）

3.1 数据版本、目标域与实际测试规模

本轮权威数据位置为服务器项目根下的 `data/`；源记录登记 train 25,079、val 3,142、test 3,124，共 **31,345 图**。14 域包括 8-calves、animals_10、CBPD_ODD、CID、CImage、COCO、COLO、Cows2021、diarycow、Google_Open_Images、HCRD、MooTrack360、NWAFU_CD、XGain。（L1 §2；L3 §2.1）

各域 test 图数见表 4。CImage 仅 17 张，CBPD_ODD 36 张，不能与 1,040 张的 Cows2021 视作等量证据。等权汇总表达的是“每个目标域同等重要”，不代表各域估计精度相同。

SHA-256 去重与清单匹配支持精确重复审计和数据版本追踪；它们不能自动排除连续帧近重复、同牛身份交叉、相同摄像头来源重叠或预训练接触。Beery 等人的固定机位新环境研究表明，同位置与新位置表现可明显不同，启发本项目继续登记来源和拍摄簇；该研究不证明本项目某域的失败原因。（R10，摘要；本记录的后续建议）

3.2 历史运行环境与初始化身份

L2 登记的环境为 **NVIDIA A100-PCIE-40GB 单卡、Ultralytics 8.4.92、PyTorch 2.5.1+cu124**；与 LODO 使用同环境。项目根为：

```
/data1/yxli/LODOANDClassbyDomain/
```

所有域从 `lodo/yolo11m.pt` 初始化；执行记录登记其 MD5 为：

```
2c2bcbb54c3829b20d31a32524ee0f03
```

这是历史记录中的身份信息，本次未下载权重重算其 hash。训练镜像会在 `run_info.json` 中登记权重路径及 MD5、Ultralytics/torch/CUDA 版本、GPU、数据规模和理论步数。本次另外对 4 份本地文档与 7 份协议/脚

本镜像计算 SHA-256，保存在来源 hash，用于确认整理期间未改动来源。

3.3 冻结配置与预算差异

表 2　统一训练与评测协议

主表：stock seed=42；es 仅改变 loader 随机流

项目	冻结设置	核验入口 / 与 LODO 关系
检测器与类别	YOLO11m；nc=1；cow	同一模型；四架构不在本轮
数据版本	data/；SHA-256 去重；8:1:1	25,079 / 3,142 / 3,124 图
初始化	lodo/yolo11m.pt	同一权重；MD5 写入 run_info
训练预算	imgsz=640；100 epochs；patience=100	固定轮数；各域优化步数不同
批与累积	batch=16；nbs=16；accumulate=1	on_train_start 断言；无梯度累积
优化器	AdamW；lr0=0.002	显式设置；禁止 auto
数值设置	AMP=True；deterministic=True	确定性设置不等于绝对确定性保证
末批与编译	drop_last=False；compile=False	末批不足 16 张也保留
增强	8.4.92 默认增强；close_mosaic=10	确切默认值仍需运行 args.yaml
保存与选模	每轮保存剥离；val AP50–95 最大	严格 > 扫描；并列较早
评测	split=test；imgsz=640；默认 evaluator	selected / epoch100 各一行；14×2=28
声明差异	单域全量；stock loader；本域 val	LODO：13 源×500；分域宏平均 val
es 扩展	seed→派生 generator；42/43/44	train_es<N> 独立目录；不替换主表

依据：重测计划 §§3–5、11；本地 indomain_protocol.yaml、训练与评测脚本。

表 2　训练规则、核验入口与 LODO 对照；默认增强的确切生效参数仍以历史 `args.yaml` 为准。

对域 t，末批保留且 accumulate=1 时，每轮理论 batch 数为：

$$B_t = \left\lceil \frac{N_t^{train}}{16} \right\rceil .$$

100 轮理论训练 batch 数为 $100B_t$。该量不应伪装成逐次记录的实际 `optimizer.step()`：AMP 跳步等运行细节需要额外日志。LODO 每轮 13×500=6,500 张、407 个 batch，末批 4 张；单域全量的预算随规模改变。由此，本实验能评价各自冻结协议下的监督参照和零样本表现，但不能将差异单独归因于域数量或样本多样性。（L1 §3；L5 训练镜像）

3.4 资产组织与本次访问边界

服务器侧历史产物的定位如下，路径均相对于上述项目根。（L2 §9）

```
indomain/
├── protocol.yaml
├── <域名>/
│   ├── logs/<run>/run_info.json
│   ├── logs/<run>/train_stdout.log
│   └── runs/<run>/
│       ├── args.yaml / results.csv
│       ├── weights/epoch0.pt ... epoch99.pt
│       ├── selected.pt / epoch100_final.pt
│       └── selection.json
├── results/
│   ├── indomain_test_results.{csv,json}
│   ├── indomain_test_results_train_es{42,43,44}.{csv,json}
│   ├── indomain_seed_repeats.{csv,json}
│   └── indomain_vs_lodo.{csv,json}
└── archive/2026-10_stock_repeats/
    ├── runs/
    ├── results/
    └── _quarantine_s43_20261006/
```

本次直接检查了 `D:\牛只数据集实验\` 的训练、选择、评测、聚合、CPU seed 测试、串行驱动器与协议镜像，共 7 份。它们支持核查**当前本地实现**；与历史远程执行源码逐字一致、远程结果文件当前存在、权重身份与全部断言实际输出，本次均未实时复核。

4. 实验步骤与过程记录（Procedures）

4.1 准备、冻结与冒烟

历史流程先确定 `data/<t>/data.yaml` 与 `splits/<t>/train.txt`，使用同一初始化和冻结参数。训练回调在 loader 构建后检查 batch/nbs=16、accumulate=1、AdamW、lr0=0.002、AMP、compile=False、resume=False、drop_last=False，以及 loader 数据规模与清单一致。（L1 §6；L2 §§2.4、3.1；L5）

正式运行前以 CImage×2 epochs 的 smoke 验证保存、优化器剥离、选择和 test 评测；执行记录报告全链路通过，e*=1 映射到 epoch0.pt，复跑指标一致。这里的冒烟是历史记录，不是本次在本机完成的 GPU 测试。（L2 §3.3）

4.2 串行执行与实际时间线

`run_indomain_all.sh` 使用 `flock` 防止同一域内驱动器双开；按域顺序串行训练。CSV 达到 100 行时视为完成并跳过；未完成的运行在下一遍从头重跑，最多三遍，不使用 optimizer resume。历史记录报告六轮完整运行各完成 14/14。（L2 §§1、11.2；L5 驱动器）

表 3　六轮完整执行与协议扩展

时间：Asia/Shanghai；年份统一为 2026

运行名	开始	结束	记录耗时	用途
train	10-05 15:53	10-06 02:55	11h01m	stock 主方案；14/14
train_s43	10-06 17:50	10-07 04:28	10h38m	stock 运行重复；14/14
train_s44	10-07 17:16	10-08 03:56	10h40m	stock 运行重复；14/14
train_es43	10-10 13:48	10-11 00:33	10h45m	有效 seed 扩展；14/14
train_es44	10-11 00:33	10-11 11:08	10h35m	接力执行；14/14
train_es42	10-11 11:08	10-11 21:55	10h47m	接力执行；14/14

原文耗时照录：主方案起止按分钟相减为 11h02m，与记录 11h01m 相差 1 分钟。
不把六轮时长之和当完整计算成本；另含恢复、HCRD 判别与冒烟。

表 3　主方案、两轮 stock 重复与三轮 es 扩展。原文主方案耗时为 11h01m，分钟级起止相减为 11h02m；差 1 分钟予以保留，未猜测秒级时间。

stock 主方案完成于 2026-10-06；es 的最后训练完成于 2026-10-11 21:55，三轮结果聚合记录于 2026-10-12。2026-10-14 是本科研记录的整理日，不能写成训练日。

Cows2021 的历史训练耗时约 3h26m、diarycow 1h23m、CImage 7m。逐域耗时和六轮时段反映工程规模，但不是完整成本账目：其中未统一计入冒烟、恢复、判别实验及所有评测时间。（L2 §1）

4.3 保存权重并按 val 选择

每轮保存一次 checkpoint，随后剥离优化器状态。镜像选择脚本读取 `metrics/mAP50-95(B)` 列，严格 `>` 扫描保留第一次达到最大值的行；登记源文件、e*、val 分数和并列信息，并输出 `selected.pt` 与 `epoch100_final.pt`。（L5 选择脚本）

映射关系为：

```
results.csv 的 epoch e（1-based）
        ↕
weights/epoch{e-1}.pt（0-based 文件名）
```

剥离后的内部 `epoch` 为 −1，不能拿它反推训练轮次；优化器状态移除后的权重也不具备完整 optimizer resume 信息。选择的可追溯性应依靠文件映射、CSV、选择记录及权重身份。（L2 §3.2；R12）

版本核查修正： v8.4.92 检测 fitness 权重为 `[0,0,0,1]`，在该实现中等于 AP50–95，不沿用旧版本 0.1×AP50+0.9×AP50–95 的说法。stock 保存 best 的相等判断仍可能使并列保留较晚轮；本项目独立选模规则更便于审计。全部历史主方案报告无并列，但本次未重新读取逐轮 CSV 验证。（R4、R5；L2 §4.1）

4.4 预定 test 评测与字段修正

选择完成后，对 selected 与第 100 轮权重各评测一次：

```
m = YOLO(str(ckpt)).val(
    data=str(data_yaml),
    split="test",
    imgsz=640,
    device=0,
    plots=False,
    verbose=False,
)
```

这是本地评测镜像核心调用的摘录；历史脚本还设置输出目录与名称。对完整一轮运行预期为 **14×2=28 条**，不因已看过 test 而再选择较高分 checkpoint。不同预先定义的重复轮可以再次评估同一冻结 test，因此“只评测一次”应指**每个预先选定权重的一次计划内评测**，不能描述成整个项目从未重复读取 test。（L1 §§4–5；L5）

镜像在评测前核对各域 test 图数。实例计数字段也已区分：

```
nt_per_class.sum() → GT 实例数
nt_per_image.sum() → 单类别下含 GT 的图像数
```

L2 §3.2 记载旧 LODO 的 `test_instances` 曾错误命名为后者；当前域内评测另存 `test_images_with_gt`，避免继续混用。表 4只列来源明确提供的 test 图数，不补造未提供的实例数。（L5；R4、R15）

4.5 排障：误覆盖、隔离、恢复与加固

2026-10-06 16:29，seed=43 驱动调用漏传 `--run-name`，写入主方案 `runs/train`，覆盖 8-calves 的 100 轮及 animals_10 前 29 轮审计材料；17:04 发现后停止。执行记录称 selected、epoch100_final、selection、run_info 及主结果 CSV 未被该训练调用触碰。（L2 §3.4）

处理步骤按原记录重建如下：

1. **界定受影响资产。** 将污染材料隔离，保留事故日志，不把全项目结果笼统宣布为损坏或无影响。
2. **修正运行命名。** 按 seed 自动派生 `train`/`train_s<N>`；显式 `train` 配非 42 seed 时硬报错；驱动器补传运行名。
3. **保护结果输出。** 增加 `--out-tag`，为子集恢复核验生成独立结果文件；es 协议另禁止写入 stock 冻结目录。
4. **从 seed=42 完整恢复。** 两域重训后核对学习曲线、e* 与 val 峰值、test 全指标三条链。

L2 §3.5 记载 animals_10 前 29 行学习列与隔离前缀一致（time 列除外）、恢复 e*=96/val=0.66209/test AP=0.66643；8-calves 100 轮一致、恢复 e*=63/val=0.59602/test AP=0.57732。事故区后于 2026-10-10 归档到表述于 §3.4 的 archive 路径。

本次核查状态： 已在本地脚本中看见运行名保护、es 目录隔离及 `--out-tag`；三重恢复通过是历史执行记录报告，本次没有重新加载远程逐轮材料验证。这一区分保留了排障成果，也保留了证据层级。

4.6 源码审计与 effective-seed 扩展

stock 重复出现长曲线逐位相同后，原先“换 seed 会改变检测头初始化”的解释被修正。L2 记录该配置下单类头通过 `cls_remap` 确定性映射，日志为 `Transferred 649/649 items`；v8.4.92 `tasks.py` 可核查按规范化类别名称复制头通道的机制。完整历史覆盖情况仍以该运行日志为依据。（L2 §5.1；R11）

同时，v8.4.92 `build_dataloader()` 中实际创建的 generator 为：

```
generator = torch.Generator()
generator.manual_seed(6148914691236517205 + RANK)
```

该 generator 不读取用户 seed，并同时参与洗牌和 worker 派生种子。因此在本记录的初始化、单卡及 loader 条件下，仅改名义 seed 的 stock 三轮主要构成**运行间重复**，不能作为有效种子重复的证据。此结论不推广到所有 Ultralytics 模型、DDP 或版本。（R3、R7；L2 §5）

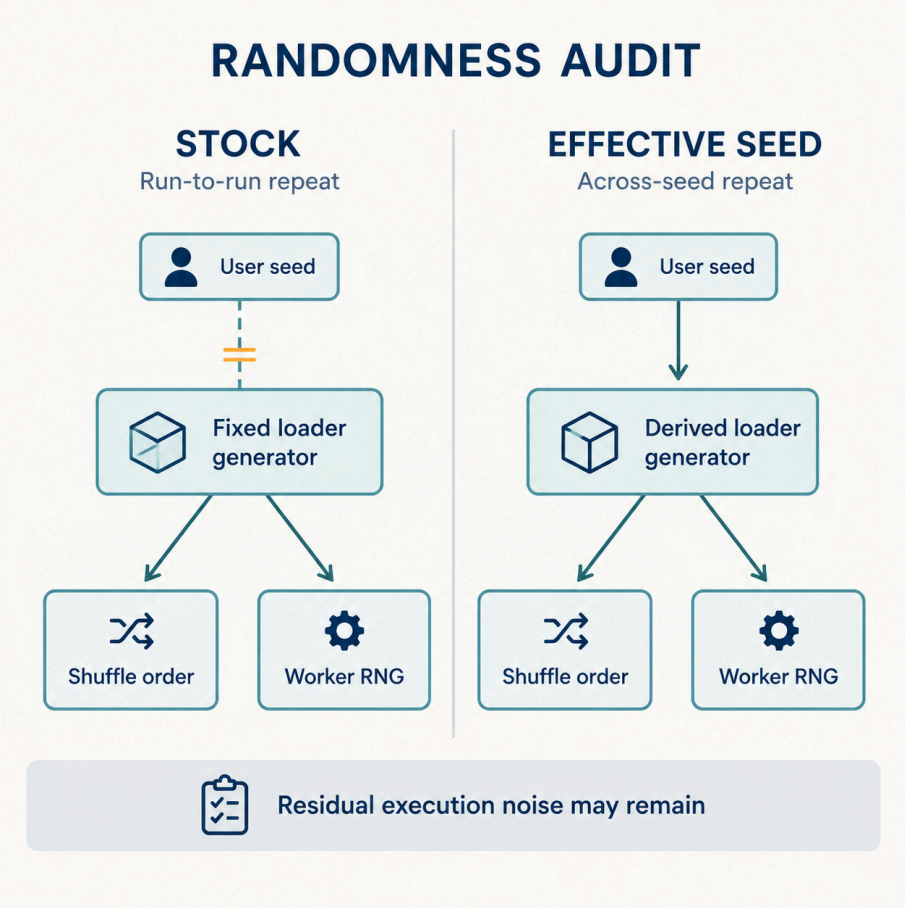


图 2　Study Image 示意：stock 的 loader generator 不由用户 seed 控制；es 覆盖为由 seed 派生的 generator，从而同时控制洗牌及 worker RNG。两套运行都仍可能存在残余执行噪声。

2026-10-09 增补 es 协议。保持训练超参、数据与选模/评测规则不变，唯一明确改动为在进程内以子类替换 `InfiniteDataLoader`，按 loader 创建顺序生成 seed+0、seed+1、… 的 generator。运行写入 `train_es42/43/44`，并存 `seed_loader_creations.json`；默认关闭开关时保持 stock 路径。（L1 §11；L5 `make_seed_effective()`）

历史扩展前验证包括同 seed 顺序一致、异 seed 首轮分叉、逐 epoch 洗牌、worker 种子分离、stock 对照不变，以及 CImage 两轮端到冒烟。L2 报告通过；本次读取了 CPU 机制测试脚本，但未在本机或服务器运行该训练环境测试。

4.7 可复现操作入口

下列为**历史复现命令入口**，本次没有执行。重新运行前须核对远程环境、协议文件和归档状态；不要把已归档 stock 重复的训练命令当成只读分析。

```
conda activate ultralytics
cd /data1/yxli/LODOANDClassbyDomain

# stock 主方案
bash run_indomain_all.sh
python3 indomain_select_checkpoint.py --all --run train
python3 indomain_eval_test.py --run train

# es 扩展示例；42/44 按各自运行名执行
bash run_indomain_all.sh 43 es
python3 indomain_select_checkpoint.py --all --run train_es43
python3 indomain_eval_test.py --run train_es43

# CPU 机制检查与三种子聚合
python3 indomain_seed_patch_test.py
python3 indomain_compare_lodo.py --es-runs train_es42,train_es43,train_es44
```

镜像聚合器扫描活跃及 archive 结果中的 stock 轮次，es 由 `--es-runs` 显式指定并单独输出。此设计可以防止两种协议静默混入同一方差表。（L5 聚合脚本）

5. 原始记录摘录与过程现象（Raw Data & Observations）

5.1 主方案逐域读数与选模轮次

表 4 YOLO11m 域内监督参照

stock seed=42 · selected.pt · frozen test · AP 数值为 0–1

目标域	test 图	e*	AP50	AP50–95	P 默认	R 默认
HCRD	106	87	0.9945	0.9468	0.9930	0.9877
CBPD_ODD	36	97	0.9860	0.9081	0.9399	0.9772
diarycow	408	100	0.9948	0.8915	0.9942	1.0000
Cows2021	1040	91	0.9922	0.8881	0.9779	0.9818
CID	205	75	0.9878	0.8676	0.9603	0.9635
XGain	163	96	0.9944	0.8301	0.9843	0.9843
NWAFU_CD	185	97	0.9127	0.7452	0.8960	0.8407
MooTrack360	150	90	0.9668	0.6703	0.9519	0.9093
animals_10	161	96	0.8524	0.6664	0.8751	0.7781
COLO	100	90	0.9550	0.6517	0.9320	0.9035
8-calves	90	63	0.9786	0.5773	0.9687	0.9657
COCO	172	93	0.7675	0.5178	0.8061	0.6792
CImage	17	95	0.7004	0.4823	0.7928	0.6958
Google_Open_Images	291	83	0.7524	0.4564	0.7647	0.7070
14 域等权宏平均	**3,124**	**—**	**0.9168**	**0.7214**	**0.9169**	**0.8838**

依据：执行记录 §4.2；宏平均由显示的四位逐域值复算。
P/R 为默认 val 的汇总工作点；不标注为 conf=0.25 严格计数。

表 4　L2 §4.2 的逐域值；e^* 来自 §4.1。数字照录或由显示精度复算，不是本次新产生的远程输出。

e* 分别包括 8-calves=63、CID=75、Google=83、diarycow=100；其余域处于 87–97。原记录“除 8-calves 外集中在 83–100”的概括漏掉 CID，本记录按表值修正。diarycow 最优轮为最后一轮，这只说明当前候选预算的 val 最大值位置，不足以证明充分收敛或继续训练无收益。

5.2 stock 重复：完全一致域与噪声域

三轮 stock 中，L2 §5.2 报告以下 11 域训练曲线、e*、val 峰值及 test 指标逐字段一致：8-calves、animals_10、CID、CImage、COCO、Cows2021、diarycow、Google_Open_Images、MooTrack360、NWAFU_CD、XGain。

表 5　stock 重复的运行间波动

11/14 域逐位一致；其余三域报告实际读数与极差

目标域	train	train_s43	train_s44	max − min
CBPD_ODD	0.90809	0.90809	0.91641	0.00832
COLO	0.65167	0.65386	0.65478	0.00311
HCRD	0.94684	0.94598	0.93760	0.00924

极差为单个正数，未写成 ±SD；三轮不能构成置信区间。
依据：执行记录 §5.2；运行名中的 seed 数字不代表有效种子变化。

表 5　三个噪声域的极差分别为 0.00832、0.00311、0.00924；这些是重复运行间范围，不是对称误差棒或置信区间。

原记录报告 COLO 前 48 轮一致、第 49 轮起分叉，HCRD 第 5 轮起分叉；CBPD_ODD 有两轮一致、一轮不同。两轮一致不能独自证明未来运行完全确定。（L2 §5.2）

表 6　HCRD 同 seed 判别记录

同 seed 重跑也发生分叉，支持存在运行间非确定性

运行	e*	val 峰值	test AP50–95
stock 主方案	87	0.92541	0.94684
stock 重复 ①	100	0.91925	0.94598
stock 重复 ②	96	0.92568	0.93760
同 seed=42 重跑	98	0.92888	0.92850

四次 test 读数跨度 0.01834；不能用三轮极差替代四轮范围。
依据：执行记录 §5.3；具体非确定性算子本次未定位。

表 6　同 seed=42 的 HCRD 重跑也从首轮与主方案不同。加入该判别运行后，四次 test 结果范围为 0.92850–0.94684，跨度 0.01834。

该结果支持残余运行间非确定性，但不能定位到某个特定 CUDA kernel。v8.4.92 用 `torch.use_deterministic_algorithms(True, warn_only=True)`；无法确定化的操作可能只发出警告。原记录“三条通道全部关闭”的强表述应收紧为：**本配置下主要 seed 通道未激活，确定性设置限制部分非确定性，但观察到残余运行噪声。**（L2 §5.3；R12）

5.3 es 生效的直接现象与结果

L2 §11.2 摘录 CImage 首轮 box/cls/dfl loss：

```
stock : 0.95283 / 2.92736 / 1.41423
es42  : 0.92338 / 2.95144 / 1.39412
es43  : 0.89472 / 2.98540 / 1.38925
es44  : 0.89429 / 2.83650 / 1.36561
```

es42 与 stock 已不同，符合 generator 随机流被替换；三种子各异则支持有效 seed 生效。选模轮次也变化，例如 8-calves 的 es42/43/44 为 58/63/79，CID 为 80/57/64。最终成绩须继续遵循 val 选模，不能根据 test 再选择 seed。（L2 §11）

表 7 effective-seed 三种子扩展

selected.pt · 同一 test 视图 · mean 与样本 SD 按原表照录

目标域	es42	es43	es44	mean	SD (n=3)
HCRD	0.9361	0.9409	0.9439	0.9403	0.0040
CBPD_ODD	0.9122	0.9070	0.9094	0.9095	0.0026
diarycow	0.8920	0.8891	0.8909	0.8907	0.0015
Cows2021	0.8902	0.8889	0.8908	0.8900	0.0009
CID	0.8662	0.8686	0.8675	0.8674	0.0012
XGain	0.8255	0.8260	0.8279	0.8265	0.0013
NWAFU_CD	0.7441	0.7484	0.7457	0.7461	0.0022
animals_10	0.6680	0.6737	0.6756	0.6725	0.0039
MooTrack360	0.6679	0.6682	0.6697	0.6686	0.0010
COLO	0.6524	0.6539	0.6461	0.6508	0.0042
8-calves	0.5654	0.5729	0.5763	0.5716	0.0056
COCO	0.5189	0.5170	0.5112	0.5157	0.0040
CImage	0.4640	0.4896	0.4993	0.4843	0.0182
Google_Open_Images	0.4581	0.4572	0.4435	0.4529	0.0082
14 域等权宏平均	**0.71865**	**0.72153**	**0.72127**	**0.72049**	**0.00159**

依据：执行记录 §11.3；完整精度原始 CSV 未重取；四位输入复算有末位舍入差。
跨 seed 的观测离散度可能叠加残余运行噪声；非置信区间。

表 7　逐域 mean 和样本 SD 按 L2 §11.3 照录，宏平均汇总为 0.72049±0.00159。完整精度 CSV 未重取；显示精度复算见附录 B。

5.4 第 100 轮敏感性对照

L2 §4.3 报告 selected 与 epoch100 的 AP50–95 平均绝对差为 **0.0089**；除 CImage 差约 0.078 外，其余不超过 0.011。CImage 的 epoch100 AP 约 0.560，高于 selected 的 0.4823，但主结果仍保持按 val 选择的 0.4823，不能事后替换。（L2 §§4.3、7）

这支持“多数域在这两种预定选择下差异较小”的有限观察。CImage 是必须保留的反例；没有完整逐轮 test 评测，也不应去寻找 test 最优轮或将差异全部归因于测试样本量。

6. 结果与数据分析（Results & Analysis）

6.1 同协议域内参照的总体水平

从表 4 显示值复算，14 域 AP50、AP50–95、默认 P、默认 R 宏平均分别为 **0.9168、0.7214、0.9169、0.8838**。AP50–95 从 Google_Open_Images 的 0.4564 到 HCRD 的 0.9468，跨域跨度为 0.4904。（L2 §4.2；本次复算）

该跨度描述统一检测器在这些目标域和当前标注定义下的难度差异，不能据此给数据集“质量”排名。test 图数、来源组成、框语义和目标尺度都可能参与变化；当前没有控制变量实验。

图 3　同一权重下的宽松检出与严格定位指标

stock selected.pt；按 AP50–95 排列；连线表示指标差，不表示定位误差的唯一原因

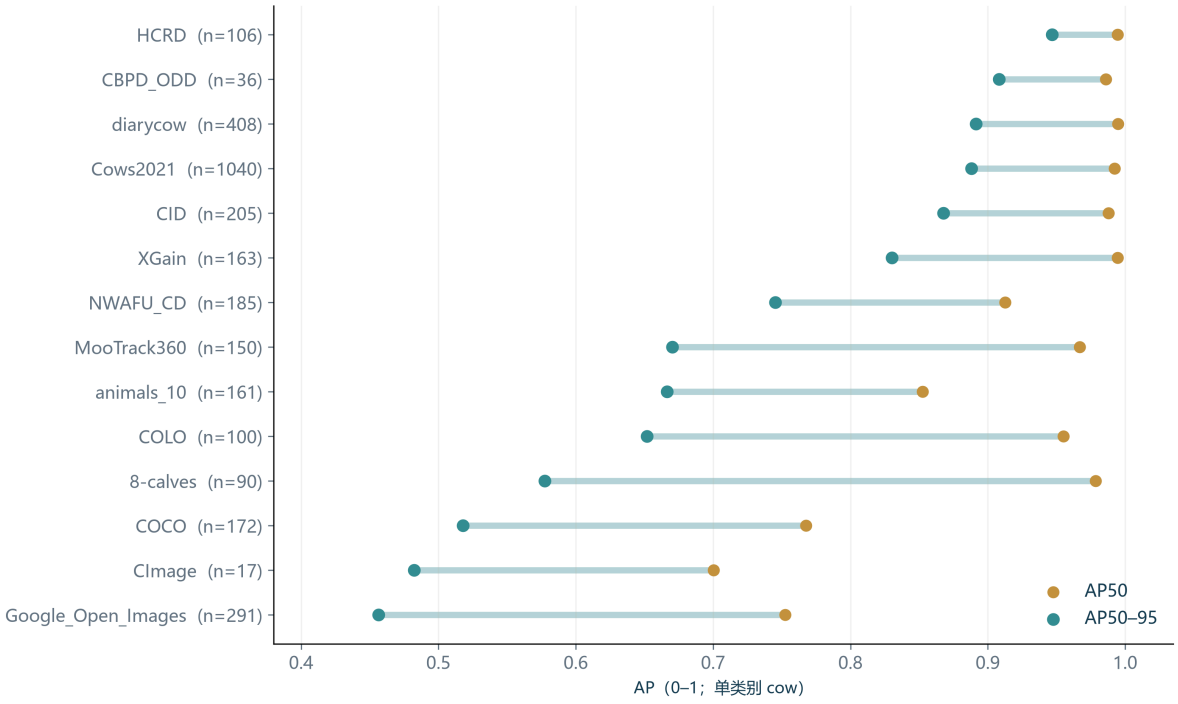


图 3　同一权重下 AP50 与 AP50–95 的配对。n 为 test 图数；连线长度是指标差，不等于某一误差原因的贡献。

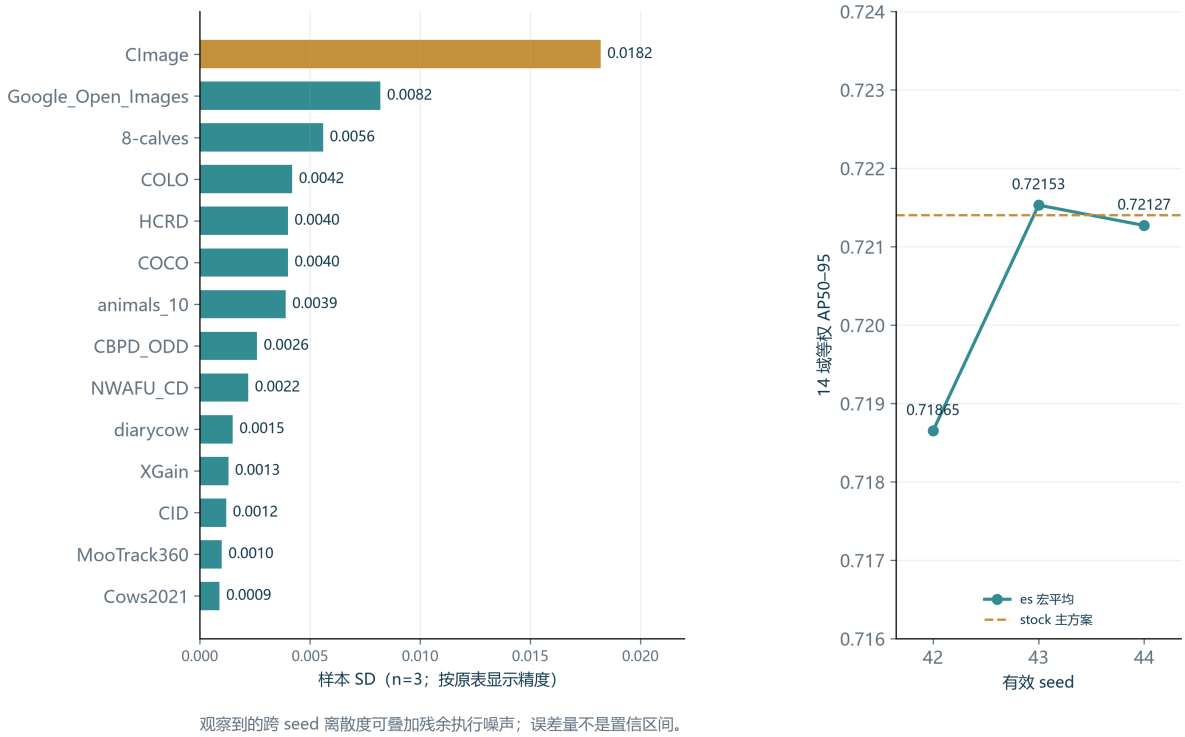
8-calves 的差为 0.4013、COLO 为 0.3033、MooTrack360 为 0.2965，提示在宽松检出之外优先审核高 IoU 定位、遮挡边界与标注语义。COCO 和 Google_Open_Images 的 AP50 本身也相对较低，需同时检查漏检与定位。这里是**误差审核优先级的综合建议**，不是已完成的逐图错误归因。

6.2 跨有效种子的总体稳健性

es 三种子宏平均为 0.71865、0.72153、0.72127；跨种子 mean±样本 SD 为 **0.72049±0.00159**。与 stock 主方案 0.7214 的差约为 **0.00091**，即约 **0.091 个百分点**，支持当前总体分数量级对该随机流变化较稳定。（L2 §11.3）

图 4　effective-seed 扩展的逐域离散度与总体读数

mean±SD=0.72049±0.00159；左图逐域 SD 与右图宏平均级 SD 的统计对象不同



观察到的跨 seed 离散度可叠加残余执行噪声；误差量不是置信区间。

图 4　左图为各域三种子的样本 SD，右图为先逐种子等权汇总后的三个宏平均。二者统计对象不同；未绘制置信区间。

CImage 的 SD=0.0182，为当前 es 表最高，约为总体宏平均 SD 的 11 倍；Google_Open_Images 为 0.0082。原文把这两域都概括为“小样本方差最大”需要区分：CImage 确实只有 17 张 test，Google 为 291 张并非本表最小集合之一。其波动不能仅凭样本量确定原因。

从显示值复算，逐域 SD 中位数约 0.0033。原表“10/14 域 SD≤0.004”依赖显示舍入：HCRD 的三位读数复算 SD≈0.003934，而 COCO≈0.004012；按显示的四位 SD 判断为 10 域，按显示三值重新计算则为 9 域。完整精度结果未重取，本记录不把临界计数作为主结论。（本次复算；附录 B）

统计边界： es 改变了有效种子，但每种子仅一轮，残余执行噪声仍可叠加在跨种子 SD 中。stock 与 es 的设计分别提供两种诊断证据，没有严格分离所有方差分量。若需分离，应增加“每 seed 多次重复”的嵌套实验；当前不作显著性声明。

6.3 与 LODO 的同目标配对及保持率

表 8　同一目标 test 上的监督参照与保持率

分母：stock 主方案；分子：LODO 三种子均值；R 不裁剪

目标域	test 图	域内 AP	LODO AP	R_target
CImage	17	0.4823	0.7169	1.486
CBPD_ODD	36	0.9081	0.9028	0.994
animals_10	161	0.6664	0.6621	0.994
COCO	172	0.5178	0.5022	0.970
Google_Open_Images	291	0.4564	0.4258	0.933
CID	205	0.8676	0.7318	0.843
diarycow	408	0.8915	0.6213	0.697
NWAFU_CD	185	0.7452	0.5057	0.679
XGain	163	0.8301	0.5584	0.673
8-calves	90	0.5773	0.3395	0.588
COLO	100	0.6517	0.3820	0.586
HCRD	106	0.9468	0.2910	0.307
Cows2021	1040	0.8881	0.2668	0.300
MooTrack360	150	0.6703	0.1394	0.208
14 域等权宏平均	**3,124**	**0.7214**	**0.5033**	**0.7328**

R_target 宏平均是 14 个域比值的平均；两个 AP 宏平均相除为约 0.6976。
依据：执行记录 §6 与 LODO 记录 §5.3；末位复算舍入差见 JSON。

表 8　LODO 均值取 L3 §5.3，分母取 L2 §4.2。逐域比值宏平均复算为 0.7327588，约 0.7328；表内三位 R 的末位可能与原表截取精度不同。

域内 AP 宏平均 0.7214，LODO 三种子均值的 AP 宏平均约 **0.5033**。逐域保持率等权平均约 **0.7328**；两个 AP 宏平均相除约 **0.6976**。二者回答不同问题，不能互换。原记录另报告 stock 三轮×LODO 三种子的九组合保持率为 0.7325，该数本次未从完整原始 CSV 独立复算。（L2 §6；L3 §5.3）

图 5　域内监督与多源零样本在同一目标视图上的配对

逐域比值宏平均约 0.7328；经验监督参照不是上限，CImage 的 R>1 如实保留

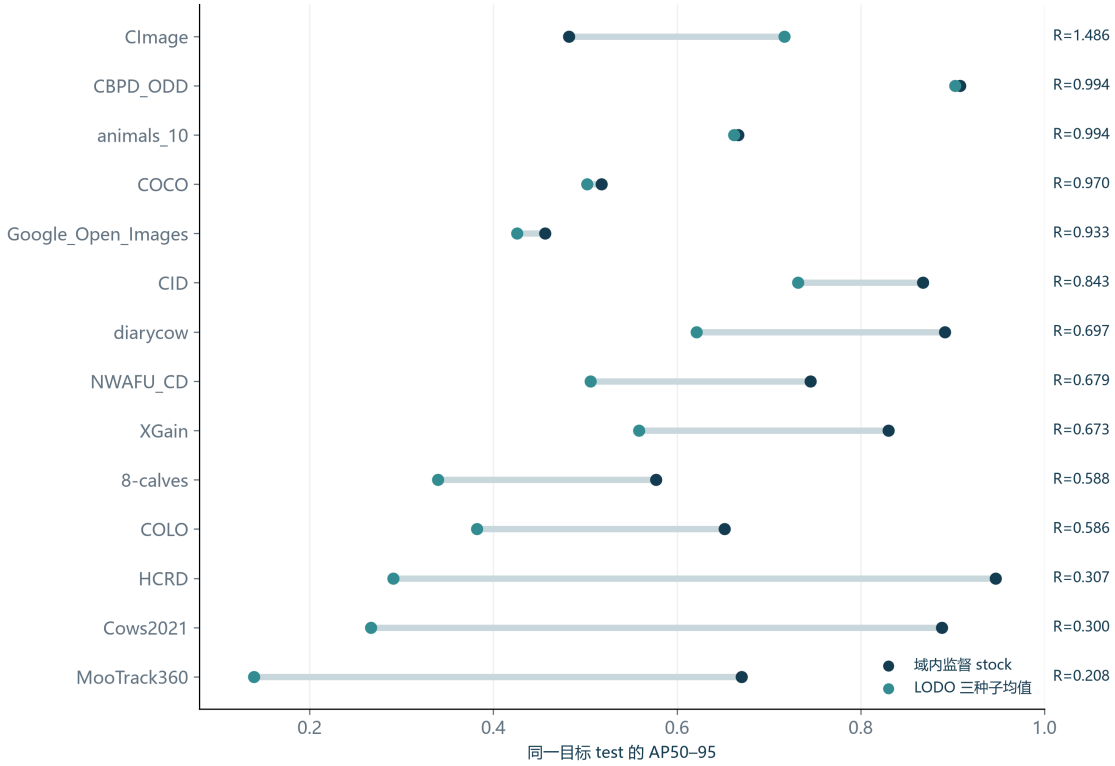


图 5　点对使用同一目标 test 的 AP50–95；右侧为逐域保持率。图中域内分母保持 stock 主方案，不替换成 es 均值。

观察可分为三组：

1. **接近域内监督的域。** CBPD_ODD 与 animals_10 的 R 约 0.994，COCO 0.970、Google 0.933；CID 为 0.843。不能把 CID 纳入“均≥0.93”的概括。
2. **保持率明显较低的域。** MooTrack360 约 0.208、Cows2021 0.300、HCRD 0.307，其余若干域约 0.59–0.70。它们指出本轮多源零样本还不能替代目标域监督；原因需要来源与误差分析。
3. **超过经验监督参照的 CImage。** 域内 0.4823、LODO 0.7169，R≈1.486。域内训练仅 141 图、test 17 图（L2 §8），适合优先研究少样本微调和多源迁移，但当前未证明过拟合或特化是唯一机制。

Cows2021 域内 AP=0.8881、R≈0.300，而 CBPD_ODD 域内 AP=0.9081、R≈0.994，说明相近的高域内分数可以对应完全不同的保持率。原记录“域内绝对水平与保持率无关”过强；本记录采用**高域内精度不足以保证高泛化保持率**，不宣称统计独立或不存在相关。

6.4 与旧记录的描述性对照

表 9　旧 val 与新 test 的历史对照

数据版本、划分、优化协议、报告视图同时变化；不解释为净提升

目标域	旧 val	新 test	算术差
HCRD	0.9327	0.9468	+0.0141
CBPD_ODD	0.9384	0.9081	-0.0303
diarycow	0.8753	0.8915	+0.0162
Cows2021	0.8600	0.8881	+0.0281
CID	0.8731	0.8676	-0.0055
XGain	0.8314	0.8301	-0.0013
NWAFU_CD	0.7371	0.7452	+0.0081
MooTrack360	0.6709	0.6703	-0.0006
animals_10	0.6808	0.6664	-0.0144
COLO	0.6508	0.6517	+0.0009
8-calves	0.5628	0.5773	+0.0145
COCO	0.5175	0.5178	+0.0003
CImage	0.7586	0.4823	-0.2763
Google_Open_Images	0.4562	0.4564	+0.0002
14 域等权宏平均	**0.7390**	**0.7214**	**-0.0176**

依据：执行记录 §7；该表仅描述不同历史协议的读数。
CImage 差值约 −0.2763；多因素变化不能单独归因于划分或微调。

表 9　旧 val 与新 test 的算术差仅帮助定位历史变化，不解释为净性能增益。

旧均值约 0.7390，新均值 0.7214，差约 −0.0176；CImage 从 0.7586 到 0.4823，差约 −0.2763。（L2 §7；本次复算）

旧 val 同时承担选模和报告，可能带来选择乐观性；但数据、划分、有效 batch 与报告视图同时变化，不能证明下降由哪一个因素导致。CImage 的 selected/epoch100 差和 es 波动提供了进一步审核入口，未构成因果分解。

7. 讨论、后续计划与阶段结论（Discussion & Next Steps）

7.1 本阶段的研究价值

本阶段的核心收获是把域内分数放回可追溯的实验流程。统一配置消除了若干明显的协议差异，冻结 test 分离了选模与报告，独立选择脚本避免依赖模糊的 best 文件语义，事故恢复保留了工程审计链，而 seed 机制核查揭示了仅修改参数名称不能保证随机流改变。（L1、L2；本地镜像核查）

对后续 CowCV 分析，新的 $M_{t \to t}$ 提供目标域监督参照，LODO 保持率补充了单独域内精度不能回答的问题。两者结合可形成更清晰的研究讨论，但不扩大为数据质量排名、环境因果解释或多源训练净收益证明。

7.2 来源冲突与采用口径

表 10 复核发现与采用口径

保留原始资料，通过当前记录明确纠正与未决事项

核对项	发现	本记录采用口径
选模轮次	原文概括漏掉 CID 的第 75 轮	8-calves=63；CID=75；其余 83–100
LODO 宏平均	§6 将 0.734/0.729/0.735 放在 AP 描述后	AP 三轮为约 0.5056/0.5009/0.5034；前者对应保持率
LODO SD	重测 §6 与 LODO §5.3 若干 SD 不同	不混用；本文保持率表省略争议 SD
stock 不确定性	三轮极差被写成 ± 数值	给原始三值及 max−min；HCRD 四轮另列
默认 P/R	评测脚本直接读取 results_dict	默认 F1 峰值汇总；非固定 conf 严格计数
预算充分性	选模靠后被当作充分收敛依据	预算完成已记录；充分收敛尚无证明
随机性分量	es 的跨 seed 差异被视为纯种子方差	观测 SD 可叠加残余运行噪声；嵌套重复待执行
时间记录	主方案起止差与耗时相差 1 分钟	照录并标注；不猜秒级时间

依据：本地源文档、镜像脚本与版本固定的官方源码；不是对原始日志的实时重审。

表 10　核查保留原始资料，通过本记录说明修正；未回写或覆盖两份实验来源文档。

还需特别保留以下冲突：

- **AP 与保持率的混用。** L2 §6 描述分子侧逐种子宏平均为 0.734/0.729/0.735；L3 §5.4 的 AP 三轮为 0.5056/0.5009/0.5034。按 L3 逐域 AP 与 stock 分母复算，前一组三数约对应逐种子保持率，故本文不把它们称为 LODO AP。
- **LODO 的 SD 字段不同。** L2 §6 的 CImage SD=0.043、CBPD_ODD=0.013 等，与 L3 §5.3 的总体 SD=0.0207、0.0115 等不一致。镜像聚合器同时计算多个比值 SD，可能存在字段转述差异，但本次没有完整原输出，不能据此确定原因。保持率主表省略争议 SD。
- **总体与样本 SD。** L3 的宏平均约 0.5033±0.0019 使用总体 SD（ddof=0）；同三轮改用样本 SD 约为 0.0024。es 扩展使用样本 SD（ddof=1），两者应标明定义后再比较。
- **测试隔离声明。** 禁止以 test 选权重及手工调参，与默认 P/R 从当前曲线峰值汇总是两件事。若文章需要固定部署工作点，应在 val 冻结阈值，再对 test 严格计数，单独命名指标。

7.3 后续执行与验收

1. **补齐远程原始证据身份。** 导出各域的 CSV、selection、run_info、args、代码版本与权重 hash，核对本地镜像；检查评测是否恰有 14 个 selected 与 14 个 epoch100 条目、实例数语义是否正确。
2. **审核小样本及来源簇。** 对 CImage、CBPD_ODD 优先登记图像来源与标注；按视频、摄像头、身份或采集批次核查近重复和划分关系，必要时再冻结新版本。抽样审阅须留逐图条目及裁决依据。
3. **嵌套重复量化不确定性。** 在重点噪声域用每有效 seed 多次运行；分别估计 seed 差异、运行噪声与 test 来源簇抽样误差，避免把 n=3 SD 当置信区间。
4. **统一部署工作点。** 保留 AP 主表；另在 val 选择或直接冻结 conf=0.25，test 上按 IoU≥0.5 一对一匹配输出 TP/FP/FN、P/R/F1，并记录预测数与阈值。

5. **补做同视图单源与预算对照。** 新 `data/`、新 test 上复核 14×14 单源迁移，再计算 Δ_{multi}；研究域多样性效果需匹配样本量、优化更新预算和选模规则。
6. **论文落点与其他模型复核。** 新 YOLO11m test 结果单独注明协议，衔接目标保持率和随机性声明；不将它直接混进旧四架构 val 表。其他架构需先冻结跨框架 evaluator、输入、训练与选模协议。

上述为待执行工作，不计入本次完成的训练、评测或错误分析。

7.4 可采用的阶段结论

> 在去重后的 `data/` 与冻结 test 视图上，YOLO11m 的 14 域域内监督参照 AP50–95 等权宏平均为 **0.7214**（stock 主方案）。有效种子扩展的三种子宏平均为 **0.72049±0.00159**（样本 SD，n=3），总体分数量级与主方案接近。stock 重复在 11/14 域记录为逐位一致，3 域存在运行间波动；HCRD 同 seed 判别进一步提示残余非确定性。以同目标 test 的 LODO 三种子平均为分子，逐域保持率宏平均约为 **0.7328**，各域差异明显且 CImage 可超过经验监督参照。高域内精度不足以保证高跨域保持率。上述结果支持当前协议下的描述性比较，不构成数据集质量排名、因果解释、理论上限或显著性结论。

本次完成： 来源阅读、镜像脚本核查、15 项官方/原始研究入口核查、表格复算、图表制作、相对链接与资料身份检查。
本次未运行： 远程训练/推理、逐图误差分析、CPU seed 机制测试、显著性检验、来源簇 bootstrap、SQLite/向量索引同步。

记录人签字： _____ **日期：** _____
审核人/导师签字： _____ **日期：** _____

附录 A. 来源、文献与定位

A.1 本地直接阅读来源

- **L1　10月域内重测计划。** 制定 2026-10-05；es 增补 2026-10-09。完整读取；重点定位 §§1–7 的协议、§10 的边界、§11 的种子扩展。
- **L2　域内重测：过程与结果。** 完整读取；§3 排障与恢复、§4 主表、§5 stock 稳定性、§6 保持率、§7 旧对照、§9 资产、§11 es 扩展。历史实验事实的主要本地依据。
- **L3　LODO测试：过程与结果。** 本次重点读取 §2.1–2.3、§5.3–5.4 及相关结果位置；用于核对新数据规模、三种子分子、SD 与保持率口径。
- **L4　实验记录格式参考。** 完整读取；采用实验目的、原理、材料、步骤、观察、结果、讨论七项结构与签字栏。
- **L5　本地实现镜像。** 只读检查以下 7 份：`D:\牛只数据集实验\indomain_protocol.yaml`、`indomain_train.py`、`indomain_select_checkpoint.py`、`indomain_eval_test.py`、

`indomain_compare_lodo.py`、`run_indomain_all.sh`、`indomain_seed_patch_test.py`。已记录 SHA-256；路径本次存在，但未确认与远程历史执行代码完全一致。

背景定位时还查看了已有多源留一域泛化记录及其来源摘要，用于衔接已有索引与辨识口径；没有用它们替代 L1/L2 原始记录。

A.2 本次自行核查的操作指南与原始研究

外部入口访问日期统一为 **2026-10-14**。官方滚动文档用于操作概念，历史机制尽量引用固定 `v8.4.92` / `v2.5.1` 源码。R9/R10 本次核查论文摘要与元信息，不称为全文精读。具体命中片段、HTTP 状态、访问时间与内容 hash 见外部来源核查。

- **R1** Ultralytics Model Training https://docs.ultralytics.com/modes/train/。定位 Train Settings；核查 optimizer、seed、deterministic、nbs 和 close_mosaic 概念。滚动页面已含其他模型内容，不将其默认值直接冒充历史生效设置。
- **R2** Ultralytics Model Validation https://docs.ultralytics.com/modes/val/。定位 Validation Arguments；核查 split、候选 conf、NMS IoU 与汇总 P/R 工作点。
- **R3** Ultralytics v8.4.92：data/build.py https://github.com/ultralytics/ultralytics/blob/v8.4.92/ultralytics/data/build.py。`build_dataloader`、`seed_worker`：固定 generator 常数与 worker 派生规则。
- **R4** Ultralytics v8.4.92：utils/metrics.py https://github.com/ultralytics/ultralytics/blob/v8.4.92/ultralytics/utils/metrics.py。`ap_per_class`、`Metric.fitness`、`DetMetrics`：平滑 F1 峰值、fitness 权重与计数字段。
- **R5** Ultralytics v8.4.92：engine/trainer.py https://github.com/ultralytics/ultralytics/blob/v8.4.92/ultralytics/engine/trainer.py。累积步数、warmup 更新与 `save_model` 相等判断。
- **R6** PyTorch v2.5.1：Reproducibility https://github.com/pytorch/pytorch/blob/v2.5.1/docs/source/notes/randomness.rst。复现限制及 DataLoader 的 generator/worker_init_fn 示例。
- **R7** PyTorch v2.5.1：DataLoader 源码 https://github.com/pytorch/pytorch/blob/v2.5.1/torch/utils/data/dataloader.py。`RandomSampler(..., generator=generator)` 与 `_BaseDataLoaderIter._base_seed`。
- **R8** COCO API：cocoeval.py https://github.com/cocodataset/cocoapi/blob/master/PythonAPI/pycocotools/cocoeval.py。10 个 IoU 阈值、101 个召回阈值与 maxDets。访问时记录 hash；用于指标定义，不声称本实验直接使用其全部实现。
- **R9** Gulrajani, I.; Lopez-Paz, D. (2020). In Search of Lost Domain Generalization https://arxiv.org/abs/2007.01434。原论文摘要：域泛化比较中的实验条件与模型选择问题；本项目的协议参考。
- **R10** Beery, S.; van Horn, G.; Perona, P. (2018). Recognition in Terra Incognita https://arxiv.org/abs/1807.04975，**ECCV 2018**。原论文摘要：固定摄像位置到新环境的识别泛化；启发来源簇审核，非本项目因果证据。
- **R11** Ultralytics v8.4.92：nn/tasks.py https://github.com/ultralytics/ultralytics/blob/v8.4.92/ultralytics/nn/tasks.py。`_remap_cls_by_names`、`load`：按类别名重映射及 Transferred 计数。
- **R12** Ultralytics v8.4.92：utils/torch_utils.py https://github.com/ultralytics/ultralytics/blob/v8.4.92/ultralytics/utils/torch_utils.py。`init_seeds` 的 warn_only 与 `strip_optimizer` 的 epoch/optimizer 改写。

- **R13** Ultralytics v8.4.92：cfg/default.yaml https://github.com/ultralytics/ultralytics/blob/v8.4.92/ultralytics/cfg/default.yaml。 版本固定的 conf 注释、NMS iou 与 max_det；不代替历史运行参数。
- **R14** Ultralytics v8.4.92：detect/train.py https://github.com/ultralytics/ultralytics/blob/v8.4.92/ultralytics/models/yolo/detect/train.py。 `get_dataloader` 中 `drop_last=self.args.compile and mode=="train"`。
- **R15** Ultralytics v8.4.92：detect/val.py https://github.com/ultralytics/ultralytics/blob/v8.4.92/ultralytics/models/yolo/detect/val.py。 AP 的 10 阈值向量与 `target_img=np.unique(cls)` 的计数语义。

附录 B. 图表、复算与审核说明

B.1 可编辑与机器可读材料

- 表格可编辑底稿：正文 10 张科研表格的 Markdown 数据，便于修改与导出。
- 逐域指标与种子结果 CSV：14 域主结果、e*、es/LODO 三种子及保持率；它是本次从文档摘录的派生表，不是服务器原始 CSV。
- 数值复算 JSON：宏平均、SD、极差、保持率、AP 差、选模轮次及显示舍入边界。
- 来源 hash与外部来源核查：本地资料身份和外部核查路径。
- 图表生成与复算脚本、外部来源核查脚本、本地复核脚本：重新生成与审核入口。
- 图表校阅总览及表格版面检查：统一视觉审阅与文字界限检查。

B.2 舍入、图像来源与诚实呈现

主方案四位逐域 AP 复算宏平均恰为 0.7214。es 四位逐域输入复算均值约 0.72048095、样本 SD≈0.00159702，与原表完整汇总的 0.72049/0.00159 存在末位差；本文保留原报告值，同时在 JSON 留下显示精度复算。完整精度原始 CSV 未重取，不用舍入数据反向覆盖实验结果。

LODO 三种子逐域表复算 AP 宏平均约 0.50559/0.50085/0.50336；总体 SD≈0.00194，样本 SD≈0.00237。保持率使用原表四位均值和域内四位分母，宏平均≈0.73275884。原表 CImage R=1.486，当前显示精度复算为 1.486419；逐项舍入差不代表实验变化。

Study Image 产物： 图 1 证据链、图 2 随机性审计、科研表格视觉母版。场景图为说明性绘制；表格母版只提供设计参考及非数据区的小装饰。10 张表格的全部文字与数字由同一程序数据精确排字；3 张统计图由 Matplotlib 绘制，未让生成模型编造曲线或改写读数。表格为 2,400 像素宽、300 dpi，统计图同为 300 dpi。

所有正文配图采用同目录 `.assets/` 相对路径，适配 Typora。图题、表题和说明保留在 Markdown 中；若只移动记录文件而遗漏资源目录，图片将无法显示。未使用伪造预测框、训练截图、签章或实验照片来充当原始证据。

由源文件 `域内重测.md` 转换生成 · 2026-10-14