数据集整理与独立测试集评估

实验编号： EXP-202607-COWCV-DATA-TEST
实验主题： 多来源牛只检测数据规范化、质量审计与域内独立测试评估
原始工作时段： 2026-07；其中基线汇总截至 2026-07-18，重复图像审计记录于 2026-07-29
整理与文献核查日期： 2026-10-13（北京时间）
记录类型： 阶段实验整理与方法复核；依据既有工作记录补充成文
记录人： 待填写　　**审核人：** 待填写
研究对象： CowCV 中 14 个单类别牛只目标检测数据集
格式依据： 实验记录格式参考中的实验记录七项结构；将“试剂与耗材”调整为“数据、软件与计算资源”。

本阶段形成的主要产出： 建立多来源图片与标签的统一训练视图，修正三套数据中的重复类别定义，完成 YOLO11m 与 RT-DETR-L 的单数据集基线，并记录 Cows2021 和 Dairy Cow 的 test 评估。随后通过内容哈希与近重复复核发现了划分污染，推动评估从“文件配对正确”进一步转向“测试样本与训练、选模过程隔离”。 [L1，§1、§4、§6–8、§13.6–13.7]



图 1　数据整理与独立测试评估的研究流程。

目　录

1. 实验目的（Objective） 3

1.1 问题与研究目标 3

1.2 本记录的证据范围 3

2. 实验原理与参考依据（Principle & References） 3

2.1 统一格式之前，先统一目标语义 3

2.2 独立测试集的判定条件 4

2.3 指标及阈值口径 5

2.4 相关研究对本项目的启示 5

3. 数据、软件与计算资源（Materials & Environment） 6

3.1 主实验环境与适用范围 6

3.2 数据与产物位置 6

3.3 14 个数据集的实际使用范围 7

4. 实验步骤与过程记录（Procedures） 8

4.1 原始资源登记与图片—标签配对 8

4.2 类别规范化与标注几何修正 8

4.3 空标签与困难场景质量决策 9

4.4 来源分组、重复审计与划分冻结 9

4.5 基线训练与权重选择 9

4.6 独立 test 评估与结果归档 10

5. 原始数据与过程现象（Raw Data & Observations） 11

5.1 主要过程节点 11

5.2 Cows2021 与 Dairy Cow 的验证、测试读数 11

5.3 重复审计及记录冲突 12

6. 结果与数据分析（Results & Analysis） 13

6.1 域内验证与 test 的关系 13

6.2 独立评估的分层结论 14

6.3 验证峰值比较的适用范围 14

6.4 由域内 test 延伸到跨数据集评估 15

7. 讨论、后续计划与阶段结论（Discussion & Next Steps） 15

7.1 本阶段的研究价值与局限 15

7.2 后续执行与验收要求 16

7.3 截至整理日的后续进展旁注 16

附录 A. 来源、文献与定位 16

A.1 本地证据 16

A.2 本次核查的官方指南与原始研究 17

附录 B. 数据、图表与复核说明 18

1. 实验目的（Objective）

1.1 问题与研究目标

牛只公开资源来自检测、分类、姿态估计和个体识别等不同任务，标签的类别、目标范围和坐标表达并不一致。直接合并目录容易把牛体部位误当整牛、把大小写不同的 `Cow/cow` 当成不同类别，或将漏标图片当作负样本。部分数据来自连续视频或同牛多视角采集，逐图片随机划分还可能使相关样本同时进入训练和评估。[L1，§3–4、§6、§9–11；L2，§1、§3]

本次工作围绕三个问题展开：

1. **数据能否可靠用于单类别检测？** 完成标签来源登记、图片配对、类别与坐标核验，保留原始资料和转换轨迹。
2. **评估集能否支撑未参与选模的性能估计？** 区分 train、val、test 的用途，检查精确重复、近重复及同来源样本跨划分情况。
3. **如何解释所得指标？** 记录数据版本、权重选择和评估条件，分开报告验证峰值、域内 test 和跨数据集结果，避免把不同协议混成模型排名。

1.2 本记录的证据范围

历史事实以《7月工作》及本地保存的结果文件为依据；**综合分析**由已记录的数量和指标推导；**方案建议**来自本次核查的官方指南和文献。未记录的执行时间、人工工时、抽检比例和显著性不补造。

本次实际完成的是本地资料核对、文献检索、数值复算、记录编写与配图；没有连接服务器重新训练或评估。历史远程路径是产物定位线索，当前存在性与运行状态未远程核查。Cows2021 的 test 指标另外与本地 JSON 对照；Dairy Cow 的指标来自月报，尚缺本次直接打开的逐次评估原始文件。 [L1；L3]

2. 实验原理与参考依据（Principle & References）

2.1 统一格式之前，先统一目标语义

本阶段工作集采用单类别 `cow`，训练标签的 class id 为 `0`。YOLO 检测标签每行对应一个目标：

```
class_id x_center y_center width height
0        0.500000 0.500000 0.200000 0.300000
```

后四项是相对图像宽、高归一化后的中心坐标和框尺寸。像素坐标水平框的转换关系为：

$$x_c = \frac{x_{\min} + x_{\max}}{2W}, \qquad y_c = \frac{y_{\min} + y_{\max}}{2H},$$

$$w = \frac{x_{\max} - x_{\min}}{W}, \qquad h = \frac{y_{\max} - y_{\min}}{H}.$$

其中 W, H 为图片实际尺寸。上述五字段、归一化坐标和零起始类别编号与 Ultralytics 官方数据格式一致。［O1，“Ultralytics YOLO format”］

格式一致仍不足以保证标注一致。 本地场景档案注明，Cows2021 原始资料含躯干旋转框，而 CowCV 视图使用水平框；《7月工作》记录当时标签视图仅保留类别 0、排除类别 1 牛背局部框，并在附录记载重新标注。两份记录描述了不同层次的标注来源，不能仅凭 `class_id=0` 推定所有数据采用完全相同的整牛边界定义。正式发布前仍需逐数据集核对“原始框、转换框、人工重标框”及遮挡目标边界约定。［L1，§6、附录；L2，§3、§4.1；O8］

2.2 独立测试集的判定条件

train 用于更新模型参数；val 用于选模和开发决策；test 用于开发方案确定后的评估。**目录名为 `test` 只是配置，不能单独证明独立性。** 还需确认测试样本未用于参数学习、权重选择、早停、阈值搜索或数据驱动的反复调参，并核验其与训练样本的来源关系。数据泄漏研究说明，不适当的划分和信息回流会产生过于乐观的性能估计。［O7；本项目综合］

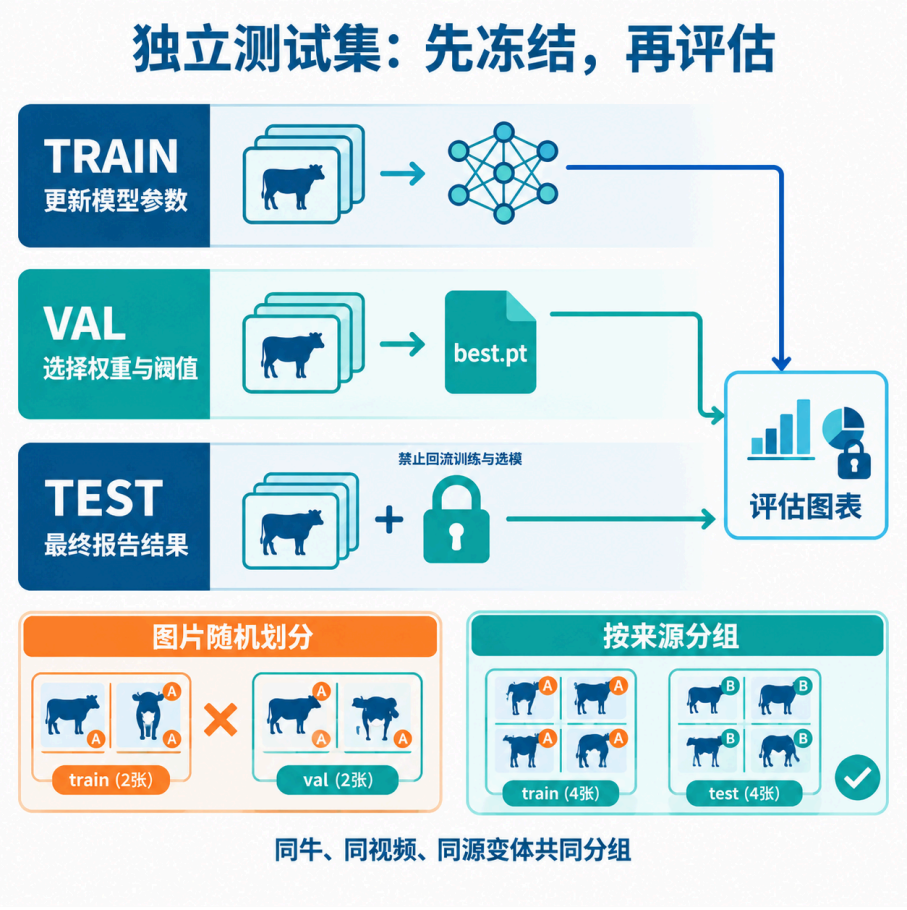


图 2　训练、验证与测试的职责及分组原则。右下的 A、B 表示不同牛只来源，张数仅用于说明分组方式。

对于同牛多视角、同一视频连续帧、同源增强版本，应先建立来源组再划分。`GroupShuffleSplit` 按组而非按图片控制划分比例，因此实际图片比例可能略有偏差；若任务强调时间外推，应另设时间段隔离与间隔，而不是把随机分组自动解释为未来时段泛化。［O4，参数与示例；O5，“gap”；本项目方案建议］

分组单元取决于研究问题： 按牛 ID 隔离可减少同一牛跨集合的关联，但不能证明不同农场、相机或时间段完全隔离；按视频分组也不必然隔离牛只身份。记录应明确要检验的是同场新图像、新牛、新机位，还是跨场景迁移。

2.3 指标及阈值口径

水平框重叠度和检测统计定义为：

$$\mathrm{IoU} = \frac{|B_{\mathrm{pred}} \cap B_{\mathrm{gt}}|}{|B_{\mathrm{pred}} \cup B_{\mathrm{gt}}|}, \qquad P = \frac{TP}{TP + FP}, \qquad R = \frac{TP}{TP + FN},$$

$$F_1 = \frac{2PR}{P + R}.$$

本记录的主指标是 mAP@0.5:0.95，即对匹配 IoU 阈值 $0.50, 0.55, \ldots, 0.95$ 的 AP 取平均；单类别时类别平均退化为该类别 AP。mAP@0.5 更宽松，应与严格定位指标同时报告。COCO 评估源码采用上述 IoU 范围，但其默认 `maxDets` 等设置与项目 Ultralytics 评估不同，不能只因指标名称相似便声称实现逐项等价。 [O2；O3，`Params.setDetParams()`]

需要特别区分：

- **置信度过滤与匹配 IoU。** `conf=0.001` 是保留预测的最低分数；`model.val(iou=0.7)` 中的 `iou` 是 YOLO 的 NMS 阈值，不能理解为 mAP 只在 IoU=0.7 上计算。
- **默认汇总 P/R 与固定阈值 P/R。** 官方验证说明及指定版本 `ap_per_class()` 表明，汇总 P/R 取自 F1 最优工作点。本记录保留历史 P/R，不将其改写为 `conf=0.25` 下的结果。
- **AP 主评估与部署阈值分析。** 后续若补固定 `conf=0.25`、匹配 IoU=0.5 的 P/R/F1，应另做预测筛选与一对一匹配，分表保存；不依靠在 test 上找最佳 F1 后反复调整部署阈值。 [O2，“Arguments” “conf” “iou”；O9，`ap_per_class()`；后两项为项目建议]

2.4 相关研究对本项目的启示

Gao 等的 Cows2021 工作及 Bristol 官方数据页提供了个体识别、视频采集和数据来源背景，提示检测视图应保留牛只与序列信息。Das 等的 COLO 研究关注拍摄角度、光照和模型复杂度对牛只定位泛化的影响，支持在本项目中同时记录数据规模与场景差异，不能仅凭域内 mAP 给数据集难度下总排名。 [O8；O10；O11]

Kapoor 与 Narayanan 的数据泄漏研究用于建立本记录的评估边界；ImageHash 项目文档用于核查 pHash 与汉明距离的工具含义。**pHash 距离阈值是本项目筛选候选的设置，并非官方认定“同图”的通用标准。** [O6；O7；L1，§13.7]

3. 数据、软件与计算资源（Materials & Environment）

3.1 主实验环境与适用范围

表 1　主实验环境与训练参数

2026-07 历史记录｜模型与参数按实际适用范围分别列出

项目	YOLO11m	RT-DETR-L
主实验平台	lab / A100-PCIE-40GB	同一主实验平台
系统 / Python	CentOS 7 / 3.10.18	月报记录的共同环境
PyTorch / Ultralytics	2.6.0+cu118 / 8.4.92	月报记录的共同环境
预训练权重	yolo11m.pt	rtdetr-l.pt
输入尺寸 / epochs	640 × 640 / 100	640 × 640 / 100
训练 batch	首批 6 项 16；后续 32	12
AMP	True	False（FP32）
worker 数	本表不补填未统一记录项	8
产物	results.csv / best.pt / last.pt	results.csv / best.pt / last.pt

来源：7月工作 §2。AutoDL CID-NOYT 与 10 月重测另属协议，不并入本表。

表 1　7 月主实验的环境与训练参数。依据 L1 §2；可编辑表格数据。首批 YOLO11m 使用 batch=16，后续使用 32，不能表述为所有实验批量完全相同。

RT-DETR-L 的 `amp=True` 训练曾在 epoch 15 后出现 NaN，改为 FP32 后记录为稳定；这一问题限定于所记录的模型、环境和尝试，不扩展为“所有 Transformer 均不适合 AMP”。CentOS 7 的旧 glibc、模型下载和结果输出目录问题也均保留为当时工程事件。 [L1，§2.5、§4.2]

2026-07-14 的 AutoDL CID-NOYT 补充实验使用 RTX 5090、Python 3.12.3、PyTorch 2.7.0+cu128、Ultralytics 8.4.60 和 FP32，与主实验环境及划分不同，单独归档。2026-10 的域内重测又使用另一数据与协议版本；三者分别记录，不交叉填充缺失环境字段。 [L1，§10.2；L5，§1–2]

3.2 数据与产物位置

以下均为《7月工作》记录的**历史路径**：

```
/data1/yxli/
├── CowsDatabases/                  原始图片
├── new_labels/                     人工复核标签
├── CowsDatabases_labels/           后续上传标签
└── CODE/ultralytics/self_mAP/
    ├── configs/                    数据集 YAML
    ├── datasets/<dataset>/
    │   ├── images/{train,val,test}/
    │   └── labels/{train,val,test}/
    ├── scripts/                    准备、训练与恢复入口
    ├── logs/                       训练日志
    └── outputs/
        ├── yolo/
        ├── rtdetr/
        └── evaluations/
```

不是所有数据集在 7 月都有 `test/`。软链接视图避免重复复制图片，但仍需检查链接目标、标签来源和断链；有坐标修正、筛选或类别合并的标签应有派生版本，不能让软链接修改悄然影响原始标签。 [L1，§2、§6、§11；后一项为项目建议]

3.3 14 个数据集的实际使用范围

表 2　14 个数据集的实际使用范围

31,373 个图片逻辑条目 | train / val / test 为 7 月视图

数据集	train	val	test	合计	划分或来源约束
Cows2021	7,248	1,023	2,131	10,402	沿用既有三划分；过滤部位类
Dairy Cow（diarycow）	3,140	560	420	4,120	整合检测与行为子集；保留 test
CID	1,645	411	—	2,056	仅 images；排除 yt_images
animals_10	1,293	323	—	1,616	图片随机 8:2；seed=42
CBPD_ODD	292	73	—	365	图片随机 8:2；seed=42
HCRD	851	212	—	1,063	图片随机 8:2；文件名解析
COCO cow subset	1,376	344	—	1,720	图片随机 8:2；单类别修正
NWAFU_CD	1,503	375	—	1,878	图片随机 8:2；单类别修正
CImage	141	35	—	176	图片随机 8:2；单类别修正
8-calves	700	200	—	900	按 amfeed/pmfeed 与来源分组
COLO（Top+Side）	803	201	—	1,004	随机 8:2；不含 External 250 张
MooTrack360	1,200	300	—	1,500	按相机或视频来源分组
XGain	1,326	331	—	1,657	UUID 原图与 _1 变体分组
Google Open Images	2,333	583	—	2,916	7 月原始视图；后续修订另计

来源：7月工作 §3、§5–7、§11。— 表示本清单未设置 test；合计不是去重样本数。

表 2　7 月主实验的数据规模、划分与来源约束。依据 L1 §3、§5–7、§11；可编辑数据。合计 31,373 个图片逻辑条目，与 7 月 29 日审计范围一致；该数量不等于去重后的独立样本数。

COLO 使用 Top+Side 共 1,004 张，未纳入公开集的 External 250 张；CID 使用 `images` 的 2,056 张，排除 YouTube 来源；MooTrack360、8-calves 使用项目实际选取的检测视图，不把原始资源的完整跟踪规模填作本实验训练量。`CBPD_ODD`、`CImage`、`animals_10` 保留项目名称，同时在来源档案说明其原始任务。 [L1；L2，§1、§3–4]

4. 实验步骤与过程记录（Procedures）

4.1 原始资源登记与图片—标签配对

依据 7 月记录，新增数据上传后先进行 ZIP CRC 校验，再建立图片与标签训练视图；标签来源须逐数据集确认。HCRD 标签名含 8 位 hash 前缀和 `%20`，通过文件名解析完成 1,063 张图片配对。 [L1，§2.3、§3.1、§11.1]

本次整理提炼的可复现检查顺序为：

1. 登记原始资源、采集子集、标签作者或来源、原始格式和实际使用范围。
2. 建立图片路径、标签路径、尺寸、来源组和内容 hash 清单。
3. 核对同名规则，区分正常辅助文件、缺失标签、重名图片、孤立标签及断链。
4. 抽图检查标签语义；格式检查通过后，再确认可见目标是否漏标。
5. 输出异常清单和处理结论，保留修正前后的标签版本。

这些字段是本次补充的归档建议，不表示 7 月已全部生成统一 manifest。原始包 CRC 检查只能验证压缩包完整性，不能替代标签语义或划分独立性检查。

4.2 类别规范化与标注几何修正

表 3　数据整理中的异常与处理

文件齐全、格式合法、目标完整和来源独立分别检查

对象	已记录问题	历史处理或决策
HCRD	标签名带 hash 前缀和 %20	解析文件名；1,063 张图片成功配对
COCO / NWAFU / CImage	同一 cow 被 Cow/cow 拆成两类	合并为 class 0；清缓存；单类别重训
Cows2021	标签视图含类别 1 牛背局部框	只保留类别 0；来源和边界语义继续核对
Dairy Cow	XML 与 JSON；行为子集含关键点	只保留 rectangle；4,120 图 / 6,050 框
COLO	13 个零宽退化框	在训练视图移除；保留原始解压标签
MooTrack360	2 个轻微越界框	在训练视图裁剪；保留原始解压标签
CVBD-5	格式合法但漏标；预标注修正负担高	当时暂不纳入训练或全量重标

来源：7月工作 §3–4、§6–7、§9、§11。处理记录不替代逐图语义复核。

表 3　有具体处理记录的异常与决策。依据 L1 §3–4、§6–7、§9、§11；可编辑数据。表中内容是历史处理记录，目标边界一致性仍需逐图复核。

对 `COCO`、`NWAFU_CD`、`CImage`，旧 YAML 的 `Cow/cow` 被拆成两类，与单类别牛检测目标不符。记录中的修复包含：标签 class id 合并为 0，统一 `classes.txt`、`notes.json` 和 YAML，清理旧缓存，并核对规范化标签哈希。旧双类别结果留在 `_invalid_two_class/`；有效结果使用 `*_new1class/`。 [L1，§3.2、§4]

三套标签对应 1,720/1,878/176 个文件和 8,647/9,206/292 个框。类别修正后 mAP50–95 分别为 0.5175、0.7371、0.7586。数值变化说明标签定义错误会严重影响指标，但修正后训练条件也应一并记录，不能把差值解释成新算法贡献。 [L1，§4；本项目综合]

4.3 空标签与困难场景质量决策

Dairy Cow 的 4,120 张图片包含 120 张空标签，转换记录中的缺失、冗余、格式错误与坐标越界均为 0。空标签应结合原图确认是否确无目标；它不能仅凭文件为空就被认定为可靠负样本。 [L1，§7；项目质量要求]

CVBD-5 虽然 5,322 张图片均有标签文件、格式正常，但抽查发现可见牛只漏标和只标部分目标；2,123 个空标签也不能直接视为无牛场景。对全量图片生成预标注后，仍需大量补框、删框和调框，当时决定暂不纳入训练。早期定位的 23 张异常图只是已确认样例，不能代表全部问题范围。 [L1，§9.1]

这项决策的依据是标签质量与人工修正负担。若后续重新启动，应先从连续帧中选取代表图片，明确局部可见牛只的纳入规则，再完成精选子集的人工标注；本次未开展新增标注或效率计时。

4.4 来源分组、重复审计与划分冻结

7 月采取的策略包括：Cows2021 沿用记录中的既有 train/val/test；8-calves 按采集来源分组；MooTrack360 按相机或视频来源分组；XGain 将 UUID 原图和 `_1` 变体分组；AutoDL CID-NOYT 按牛 ID 分组。其他若干数据仍采用固定 seed=42 的图片随机 8:2 划分。 [L1，§3.1、§6、§10.1、§11.1]

分组策略只说明所控制的关联，不能推导出所有来源关联均已隔离。7 月 29 日审计进一步采用两级核查：

1. **SHA-256 精确审计：** 对真实图片内容计算哈希，检查同一数据集内及跨数据集重复，同时保留逻辑路径与真实路径。
2. **pHash 候选检索：** 使用 64 位 DCT pHash；汉明距离 ≤4 为严格候选，5–8 为宽松复核候选，辅以 dHash；排除 SHA-256 相同对后，再人工复核跨数据集候选。

上述设置来自历史审计记录。最终“确认同图”依赖人工复核，不能仅凭 pHash 候选计数删除图片。 [L1，§13.6–13.7]

后续冻结建议： 在类别、语义和重复关系确认后，保存去重组、来源组、train/val/test 清单、标签与图片 hash、处理理由和版本号。来源关系可能交叠时，应把关联样本合并为共同组后划分。对仅有 train/val 且已经用 val 选模的数据，新增独立 test 时需确认哪些图片从未参与既有训练和选择；若重新划分，应重新训练，不能把旧权重直接当作新划分的无泄漏结果。

4.5 基线训练与权重选择

主实验训练脚本复用单类别数据视图。RT-DETR-L 于 2026-07-16 23:13 启动，经历暂停与恢复，14 项于 2026-07-18 12:58 完成；记录注明每项有 100 行 `results.csv` 与 `best.pt/last.pt`。YOLO11m 同样形成 14 项有效结果。 [L1，§1、§8.1、§12]

选模需同时保存 `results.csv` 中的目标指标、选中 epoch、实际 checkpoint 和选择规则。**最高 mAP50–95 行与文件名 `best.pt` 不应未经核查便视为同一权重。**《7月工作》对 Google 数据记录了 epoch 89 的 mAP50–95=0.4562 和 epoch 74 的 `best.pt` =0.4553，并将后者归因于综合 fitness；本次打开的官方 v8.4.92 `Metric.fitness()` 权重为 `[0,0,0,1]`，即仅使用 mAP50–95，两者存在需追溯的冲突。［L1，§11.3；O9，`Metric.fitness()`］

本记录保留历史描述并将原因列为待核实。后续应核对当时实际安装源码、是否存在自定义改动、训练参数和 checkpoint 元数据；不根据当前源码反推历史训练一定采用相同实现。

4.6 独立 test 评估与结果归档

历史 Cows2021 评估使用本域最佳权重和 test 2,131 张；Dairy Cow test 420 张。评估前应确认 YAML 显式配置 test、真实清单数量与记录一致，并保存所用权重的内容 hash。［L1，§6–7；后半项为归档建议］

下面是依据官方接口及本地已保存协议整理的**复现示例**，本次未在服务器执行，也不表示完整复刻每一次 7 月测试：

```
from pathlib import Path
from ultralytics import YOLO

root = Path("/data1/yxli/CODE/ultralytics/self_mAP")
weights = root / "outputs/yolo/Cows2021/weights/best.pt"
data = root / "configs/Cows2021.yaml"  # 执行前核对实际路径与 test 清单

metrics = YOLO(str(weights)).val(
    data=str(data),
    split="test",
    imgsz=640,
    batch=12,
    conf=0.001,
    iou=0.7,        # YOLO NMS 阈值；不是 AP 匹配阈值
    max_det=300,
    device=0,
    workers=8,
    plots=True,
    project=str(root / "outputs/evaluations"),
    name="Cows2021_test_reproduce_20261013",
    exist_ok=False,
)

print({
    "precision": float(metrics.box.mp),
    "recall": float(metrics.box.mr),
    "map50": float(metrics.box.map50),
    "map50_95": float(metrics.box.map),
})
```

`batch=12/conf=0.001/iou=0.7/max_det=300` 可在本地 Cows2021 JSON 的 `signature` 中定位。该文件记录的是已归档评估；不把这些参数补写为 Dairy Cow 测试的已确认参数。正式复现需核对模型类别、图像预处

理、软硬件版本和是否覆盖既有输出。 [L3；O2]

结果归档至少应同时包含：数据清单与 hash、YAML、checkpoint 与 hash、评估参数、图像/实例数、机器可读指标、评估日志及错误样例。`max_det=300` 在密集场景可能构成输出限制，需核对每图实例分布并披露；如调整参数，应新增协议版本，不只对某个模型单独放宽。

5. 原始数据与过程现象（Raw Data & Observations）

5.1 主要过程节点

- **2026-07-11：** 首批 6 个 YOLO11m 数据集实验；发现 COCO、NWAFU_CD、CImage 的双类别错误。 [L1，§2.4、§3]
- **2026-07-14：** AutoDL 完成 CID-NOYT 按牛 ID 分组的补充自测。 [L1，§10]
- **2026-07-16：** 新增 4 个数据集的 YOLO11m 串行训练完成；当晚启动 RT-DETR-L 系列。 [L1，§8.1、§11.2]
- **2026-07-18 12:58：** 14 个 RT-DETR-L 实验记录为全部完成；主实验两模型各形成 14 项有效单数据集结果。 [L1，§1、§8.1]
- **2026-07-29：** SHA-256 和 pHash 审计记录了内部跨划分重复及跨数据集近重复；同时新增原始预训练模型评估基线。 [L1，§13.6–13.8]

未写明日期的标签修正、转换和 test 评估不在这里虚构到具体某天。上述节点来自记录的明确日期，未重新读取历史服务器任务日志。

5.2 Cows2021 与 Dairy Cow 的验证、测试读数

表 4　YOLO11m 的历史验证与 test 读数

保留四位小数 | 验证读数来自选中轮次；test 使用对应权重

数据集 / 集合	图片	P	R	mAP50	mAP50–95
Cows2021 / val	1,023	0.9751	0.9796	0.9916	0.8600
Cows2021 / test	2,131	0.9421	0.9937	0.9809	0.8629
Dairy Cow / val	560	0.9956	0.9946	0.9949	0.8754
Dairy Cow / test †	420	0.9902	0.9870	0.9945	0.8820

来源：7月工作 §6–7；Cows2021 test 经本地 JSON 核对。† Dairy Cow 后发现 train 重复。

表 4　YOLO11m 历史验证与 test 读数，均保留四位小数。依据 L1 §6–7；Cows2021 test 另外由 L3 核对。可编辑数据。Dairy Cow test 后来发现重复污染，见 §5.3。

Cows2021 的本地 JSON 包含 `split="test"`、`images=2131`、源权重路径及 mAP50–95=0.8629461777139316，与月报四位小数一致。Dairy Cow 的记录中，验证峰值为 epoch 100，test

mAP50–95=0.8820；本次未取得独立的 Dairy Cow test JSON，不额外填充其评估实例数、阈值或耗时。［L1；L3］

历史产物位置：

```
# Cows2021（L1 §6）
outputs/yolo/Cows2021/weights/best.pt
outputs/evaluations/Cows2021_test/

# Cows2021 的本地 JSON 对应一次已归档评估（L3）
/data1/yxli/CODE/ultralytics/OOD/Cows2021OOD/
  results/yolo11m/runs/Cows2021_test/

# Dairy Cow（L1 §7）
outputs/yolo/diarycow/weights/best.pt
logs/diarycow_yolo11m_100e_b32_amp.log
runs/detect/outputs/evaluations/diarycow_test/
```

同一 Cows2021 指标在两份材料中指向不同记录目录，本次以“读数一致”作为核验结论，不据此认定两个目录是同一次运行或内容完全相同。

5.3 重复审计及记录冲突

SHA-256 审计范围为 31,373 个图片逻辑条目、31,373 个物理文件、31,254 个唯一哈希和 112 个重复哈希组。跨数据集精确重复组为 0；**数据集内部仍有跨划分重复。** ［L1，§13.6］

表 5　评估样本中的已确认重复风险

2026-07-29 审计 | 精确重复与人工确认近重复分别报告

类型	数据集 / 方向	图片数	目标集占比
精确重复	Dairy Cow：train → test	18	4.29%
精确重复	Dairy Cow：train → val	4	0.71%
精确重复	NWAFU_CD：train → val	5	1.33%
精确重复	XGain：train → val	3	0.91%
精确重复	Dairy Cow：val 与 test	5	月报未列占比
确认近重复	COCO train → Google val	7	1.20%
确认近重复	Google train → COCO val	2	0.58%

来源：7月工作 §13.6–13.7。占比是图片比例，不等于指标偏差；不合并未去重的计数。

表 5　影响评估的已记录重复关系。依据 L1 §13.6–13.7；可编辑数据。精确重复与近重复分开计数，表中“图片”不能与 pHash 全部候选“图片对”混加。

冲突一：文件检查与内容检查。 Dairy Cow §7.2 早期记录“无跨划分重复”，而 §13.6 后来确认 train→test 有 18 张精确重复、val↔test 另有 5 张。后者有明确审计方法与内容级判定，应据此修订结论：早期配对和文

件名检查通过，尚不能证明评估独立。两类重复是否涉及相同评估图片，本记录没有成员清单证据，不相加成“23 张独立污染样本”。

冲突二：来源分组与精确重复。 XGain 早期记录原图及 `_1` 变体分组，来源组跨划分为 0；后续 SHA-256 仍发现 train→val 3 张重复，说明当时的组名规则未覆盖全部内容重复关系。不能用“已分组”覆盖后续审计结果。 [L1，§11.1、§13.6]

pHash 共发现严格跨数据集候选 33 对，人工复核确认均为同一底层图片的重编码或缩放版本；其中 COCO↔Google 有 28 对，9 对跨 train/val。宽松跨数据集训练到评估候选 9 对均为场景相似误报。数据集内部的 19,306 对严格 train→val/test 候选没有在该记录中全部获得同图确认，不能写成“19,306 对已确认泄漏”。 [L1，§13.7]

在原始图像不变、模型权重不变的前提下，COCO 或 Google 目标评估视图修订会影响所有使用这些目标图像的结果。7 月记录建议优先重跑两个已确认受泄漏影响的定向单元；后续本地 `TargetUnifyTests` 则记录统一更新这两个目标列和 Cows2021 test 列，避免不同源模型使用不同目标样本集合。前者是优先修复范围，后者是完整矩阵口径一致性的补充。 [L1，§13.7；L4]

6. 结果与数据分析（Results & Analysis）

6.1 域内验证与 test 的关系

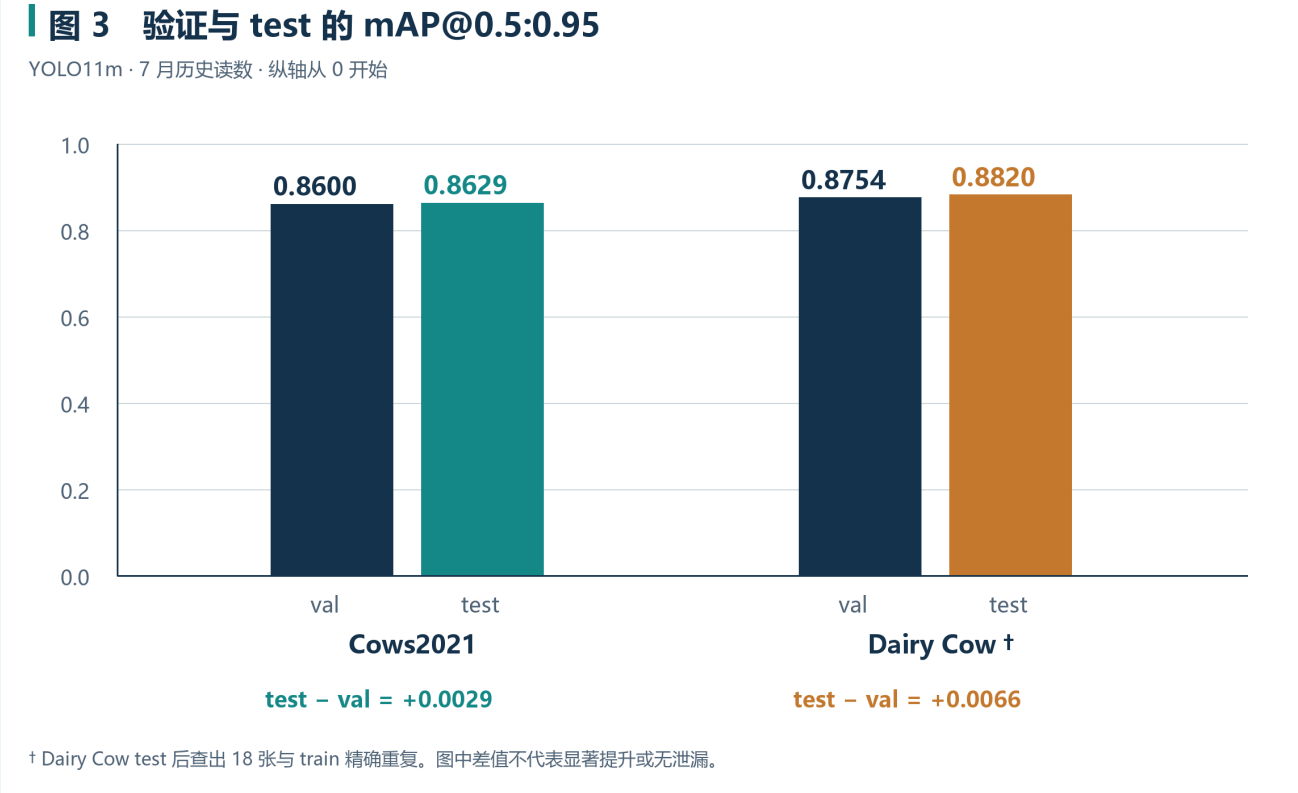


图 3　依据 L1 表中四位小数制作的确定性绘图；数据见表 4。无误差条，因为本轮历史读数不包含重复实验的不确定性。Dairy Cow test 使用带提示的配色，提醒其存在后续查出的训练重复。

用历史读数计算 test−val 的 mAP50–95 差：

$$\Delta_{\text{test}-\text{val}}^{\text{Cows2021}} = 0.8629 - 0.8600 = +0.0029,$$

$$\Delta_{\text{test}-\text{val}}^{\text{Dairy Cow}} = 0.8820 - 0.8754 = +0.0066.$$

两组 test 与 val 的数值较接近，且 test 略高。**这只能作为同一历史实验的描述性观察，不能证明测试更容易、泛化更好或不存在过拟合。** 集合构成、目标难度和采样变化都可能影响差值；Dairy Cow 还存在已确认的训练重复，没有清理后的重新评估就不能量化泄漏抬高指标的幅度。

Cows2021 test 的 mAP50 与 mAP50–95 相差 0.1180，Dairy Cow 相差 0.1125。这说明严格 IoU 范围下得分更低，提示应继续分析框边界和遮挡目标；具体误差类型仍需查看预测与真值，不能仅凭差值指定因果。［由表 4 计算；综合分析］

6.2 独立评估的分层结论

Cows2021： 有 train/val/test 划分记录，test 2,131 张和评估读数获得本地 JSON 支持，可以保留为“既有划分上的域内 test 结果”。本次未直接复核原始分组清单、所有测试样本来源或训练日志，因此不升级为“同牛、同视频、同相机、同农场均已完全隔离”的结论。

Dairy Cow： 有单独 test 420 张和高指标，但审计确认其中 18 张与 train 精确重复，占 test 的 4.29%。保留 0.8820 作为历史结果，同时标注划分污染；正式无泄漏评估应使用修订视图和重新核验的结果。4.29% 是受影响图片比例，不是 mAP 的偏差或可信度折扣。

AutoDL CID-NOYT： 按 514 个牛 ID 分为训练 411 组/1,644 张、评估 103 组/412 张，同一牛四视角不跨组；best epoch 73 的 mAP50–95 为 0.8760。月报将 412 张写为 `test/val`，又以验证指标选 best，缺少第三个隔离集合，因此应称为“按牛 ID 分组的验证/自测”，不能当作未参与选模的独立 test。它与 lab CID 的 1,645/411 图片随机划分结果也不能直接横向归因。［L1，§5、§10］

其余 12 个主实验数据集： 7 月清单只有 train/val，不把验证峰值改名为 test；正式比较需建立冻结 test，并确保旧训练与选模记录没有污染新测试样本。［L1，§14；项目方法判断］

6.3 验证峰值比较的适用范围

7 月两模型验证峰值比较中，RT-DETR-L 在 14 项中的 9 项更高，YOLO11m 在 5 项更高。这一结果说明各模型在已记录训练与选择条件下的域内验证表现，不构成统一预算的正式架构排名，也不能替代独立测试或跨数据集泛化。两模型 batch、AMP 等条件不同，首批 YOLO11m 的批量与后续也不同；“均训练 100 epoch”不等于优化预算严格相同。［L1，§2.4、§8.3］

CImage 的验证集只有 35 张，YOLO11m 在 epoch 1 达峰。该现象提示应检查小样本选择偏差和训练动态，但仅靠峰值轮次不能证明因果意义上的过拟合。样本量、验证曲线、选模规则和独立 test 都应一起分析。［L1，§4.2、§8.3；综合分析］

6.4 由域内 test 延伸到跨数据集评估

零样本迁移使用源域训练的权重直接测试目标域，不使用目标域图像进行训练、选模或阈值搜索。若目标域只有冻结 val，报告应明确写“跨数据集冻结验证视图”，而非笼统称“独立 test”。 [L1，§13.1、§13.3、§13.5]

对源域参照的保持率：

$$R_{\text{source}}(s,t) = \frac{\text{mAP}_{s \to t}}{\text{mAP}_{s \to s}},$$

回答“该源模型迁移后相对源域水平保留多少”。若改用目标域监督模型作分母：

$$R_{\text{target}}(s,t) = \frac{\text{mAP}_{s \to t}}{\text{mAP}_{t \to t}},$$

则回答“迁移模型达到目标域监督参照的多少”。两种分母含义不同，所有分子、分母都需注明数据视图与版本。跨域保持率不是域内 test 合格与否的指标，且在分母接近 0 时不稳定；本记录不补造未完成或未核查的跨域数值。

14 数据集指标汇总应先逐数据集计算，再等权宏平均；合并所有图片计算的 pooled AP 是另一种量，不能互换。若计算微调增益，原始预训练基线也需在相同目标视图上评价。COCO 预训练模型的 `cow` 类编号与项目单类 `0` 不同，历史记录采用临时 `0→19` 标签映射并限定 `classes=[19]`，原始标签保留。 [L1，§13.2、§13.8；L4]

7. 讨论、后续计划与阶段结论（Discussion & Next Steps）

7.1 本阶段的研究价值与局限

本阶段的工作价值在于建立了从图片和标签到训练权重、测试读数、重复审计的追溯链。重复类别修正解决了目标定义错误；格式检查和人工抽图揭示了“标签文件齐全”与“标签质量合格”的差别；后续内容审计又揭示了“文件名或来源规则无重叠”与“样本内容独立”的差别。

当前记录的主要局限是：7 月测试视图并未覆盖全部 14 数据集；Dairy Cow 历史 test 有污染；部分训练参数与 checkpoint 选择记录存在版本差异；Cows2021 水平框来源与整牛语义仍需核对；历史结果缺乏本次直接复核的成员级审计材料和重复实验不确定性。

7.2 后续执行与验收要求

表 6　后续执行与验收要求

面向正式评估的方案 | 完成情况以对应版本记录为准

任务	执行重点	验收产物
标签语义复核	核对整牛 / 部位 / 水平框来源与遮挡规则	来源表、规范、最终批准标签
重复与来源隔离	合并精确重复、确认近重复及来源关联组	成员清单、处理理由、跨组审计
三划分冻结	test 不参与训练、选模与阈值搜索	split 清单、版本号与内容 hash
污染结果修订	清理评估视图；训练集变化时重新训练	旧 / 新协议、权重及结果对应表
权重选择核验	追溯 Google fitness 与最高指标冲突	实际源码、选中 epoch、checkpoint hash
统一报告与复现	分别报告 AP 与固定阈值 P/R；记录重复运行	metrics、日志、错误样例及不确定性

方案依据：7月工作、后续统一目标视图记录与本次方法核查；不把计划写成已完成实验。

表 6　由历史问题提炼的改进任务及验收产物。可编辑数据。本表是整理后的方案，完成状态以对应版本的后续记录为准。

对于测试集清理，先生成带删除或重分配理由的修订清单，保持原始数据与旧读数可追溯。若仅移除污染测试样本，可以复评固定旧权重，报告为“清理后的评估视图”；若重划训练数据，则重新训练并选模，报告为新的实验版本。二者不能混写为同一次复现。

若增加置信区间，建议按牛 ID、视频或来源组进行组级重采样，而非默认把连续帧看作独立样本；重复训练的种子离散度与测试样本重采样的不确定性也应分别解释。该项为后续方法建议，本记录不提供虚构误差条或显著性检验。

7.3 截至整理日的后续进展旁注

本地《域内重测-10月》记载，2026-10-05 至 10-08 已在新的 `data/` 去重与 8:1:1 划分上重建 YOLO11m 的 14 个域内 test 参照，2026-10-09 至 10-12 扩展有效种子重复。该阶段改变了数据版本、训练协议与选模方式，属于后续实验；本记录保留 7 月读数，不将 10 月结果回填为 7 月完成事项。 [L5，§1–2、§11；本次未远程复核]

截至 7 月的阶段结论： 多来源数据已形成有效的单类别检测基线，Cows2021 提供了可定位的域内 test 参照；Dairy Cow 的高 test 指标需附带后续发现的重复污染说明。后续正式评估应以标签语义一致、来源与重复关系隔离、val 选模和冻结 test 为共同前提，按版本保留历史结论。

附录 A. 来源、文献与定位

A.1 本地证据

- **[L1]** 7月工作。主来源；§2 环境与目录，§3–4 类别错误，§6–7 test 结果，§9 质量决策，§10 CID-NOYT，§11 新数据准备，§13.6–13.7 重复审计。

- **[L2]** 14 个牛只检测数据集的拍摄环境与场景。§1–4：原始任务、实际子集、采集来源及 Cows2021 标注几何差异。
- **[L3]** Cows2021 本地评估 JSON。`records` 中 `in_domain=true`：2,131 张 test 图像、权重和协议签名、四项指标。
- **[L4]** TargetUnifyTests 冻结统一目标视图说明。目标列视图、近重复修订、统一评估参数及新旧结果关系。
- **[L5]** 域内检测重测：过程与结果。§1–2 与 §11：后续数据版本与独立 test 协议，限用于 10 月进展旁注。
- **[L6]** 测试方法。既有二手文献线索；本文回溯其中相关研究与官方资料，未直接采用其“自测可验证标注质量”等过强表述。
- **[F1]** 实验记录格式参考。仅作为编排格式，不作为实验结果证据。

另读取 7月汇报及本目录既有 Label Studio 科研记录的相关段落，核对研究脉络与版式；核心数字采用 L1/L3，不把摘要或调研建议当作新实验。

A.2 本次核查的官方指南与原始研究

以下资料于 **2026-10-13** 检索并阅读相关章节。持续更新的官方页面用于核查接口和方法，不证明 7 月安装版本或实例状态；指定版本源码用于发现待追溯冲突。

- **[O1]** Ultralytics. Object Detection Datasets Overview https://docs.ultralytics.com/datasets/detect/。定位：`Ultralytics YOLO format`；数据 YAML、目录和五字段归一化坐标。
- **[O2]** Ultralytics. Model Validation https://docs.ultralytics.com/modes/val/。定位：`Arguments`、`conf`、`iou`、`split`、指标读取；核查 test 入口及阈值语义。
- **[O3]** COCO authors. COCOeval 源码 https://github.com/cocodataset/cocoapi/blob/master/PythonAPI/pycocotools/cocoeval.py。定位：`Params.setDetParams()`、`summarize()`；IoU 范围与默认 maxDets。源码未固定 commit，不用于声称历史二进制实现相同。
- **[O4]** scikit-learn. GroupShuffleSplit https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupShuffleSplit.html。定位：按组划分、`test_size` 针对组数、`random_state` 和示例。
- **[O5]** scikit-learn. TimeSeriesSplit https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.TimeSeriesSplit.html。定位：时间顺序与 `gap`；仅借鉴时序隔离思路，未在本次执行交叉验证。
- **[O6]** Johannes Buchner et al. ImageHash 项目文档 https://github.com/JohannesBuchner/imagehash。定位：支持的哈希算法、`hash1-hash2` 汉明距离与 hash size；未引用其为项目阈值提供通用保证。
- **[O7]** Kapoor S, Narayanan A. *Leakage and the reproducibility crisis in machine-learning-based science*. Patterns, 2023, 4(9):100804. 论文 https://doi.org/10.1016/j.patter.2023.100804；作者预印本 https://arxiv.org/abs/2207.07048。用于数据泄漏与评估独立性的论证。
- **[O8]** Gao J et al. *Towards Self-Supervision for Video Identification of Individual Holstein-Friesian Cattle: The Cows2021 Dataset*. 2021. 作者论文 https://arxiv.org/abs/2105.01938。阅读摘要与数据背景，用于确认资源原始研究任务；具体 CowCV 标签处理以 L1/L2 为准。

- **[O9]** Ultralytics v8.4.92. metrics.py 指定版本源码 https://github.com/ultralytics/ultralytics/blob/v8.4.92/ultralytics/utils/metrics.py。定位：`ap_per_class()`、`Metric.fitness()`；P/R 工作点及 fitness 冲突核查。
- **[O10]** Das M, Ferreira G, Chen C P J. *A Model Generalization Study in Localizing Indoor Cows with COw LOcalization (COLO) dataset*. 2024. 作者预印本 https://arxiv.org/abs/2407.20372。本次阅读摘要及研究问题；引用角度、光照、模型复杂度研究范围，不复制本地二手笔记未经核对的效应大小。
- **[O11]** University of Bristol. Cows2021 Dataset 官方数据页 https://data.bris.ac.uk/data/dataset/4vnrca7qw1642qlwxjadp87h7。定位：资源说明、配套论文与代码；原始资源和 CowCV 派生视图分别记录。

附录 B. 数据、图表与复核说明

- 表格数据 Markdown：六张表的可编辑文字，便于复制与复核。
- 图表数据 JSON：数值、表头、来源与绘图数据。
- 图表生成脚本：在 Study Image 表格版式基础上确定性排字；统计图使用精确数值绘制。
- 本地来源校验：本次读取的主要文件路径、长度与 SHA-256；用于确认来源原文未被本次改写。
- 复核结果：链接、配图、元数据、数值与语法检查结果，以及未运行的远程评估和索引同步。
- 知识库来源摘要：资料关系、关键事实和冲突索引。

图像说明： 图 1、图 2 及表格版式母图由 Study Image 生成；表 1–6 的正文和数值由程序排入，图 3 由数值绘图。示意图片与真实实验结果分开标注；不把生成图片当作标注样例、服务器截图或泄漏复核 contact sheet。

本次复核范围： 检查本地链接、相对图片路径、来源文件完整性、六张表的数量与四位小数读数、计算差值、JSON 与绘图输入、图像可读性和新增索引条目。训练、远程评估、原始图像逐图审查、数据库与向量索引同步、统计显著性检验均未运行。

记录人签字： _____ **日期：** _____

审核人 / 导师签字： _____ **日期：** _____

由源文件 `数据集整理与独立测试集评估.md` 转换生成 · 2026-10-14